

利用大型语言模型进行工具学习：综述

Changle QU¹, Sunhao DAI¹, Xiaochi WEI², Hengyi CAI³, Shuaiqiang WANG², Dawei YIN², Jun XU(B)¹, Ji-Rong WEN¹

1 中国人民大学高瓴人工智能学院，北京，100872，中国

2 百度公司，中国北京 100193

3 中国科学院计算技术研究所，北京 100864，中国

©高等教育出版社 2024 年

摘要：近年来，使用大型语言模型（LLMs）进行工具学习已成为增强LLMs处理高度复杂问题能力的一种有前景的范例。尽管在这一领域受到了越来越多的关注，并取得了迅速的进展，但现有的文献仍然分散且缺乏系统组织，给新来者带来了进入的障碍。这一差距促使我们对现有的关于LLMs工具学习的作品进行全面的调查。在这项调查中，我们专注于从两个主要方面（1）为什么工具学习是有益的，（2）如何实现工具学习）对现有文献进行审查，以全面了解LLMs工具学习。首先，我们从六个具体方面探讨了“为什么”，即工具集成的益处和工具学习范例的内在益处。在“如何”方面，我们根据工具学习工作流程中的四个关键阶段（任务规划、工具选择、工具调用和响应生成）的分类法对文献进行了系统审查。此外，我们还对现有的基准和评

估方法进行了详细的总结，并根据它们与不同阶段的相关性进行了分类。最后，我们讨论了当前的挑战，并概述了未来可能的发展方向，旨在激发研究人员和工业开发者进一步探索这一新兴且有前景的领域。

关键词：工具学习、大型语言模型、代理

1 引言

锋利的工具能做出好活儿。

—《论语：卫灵公》

纵观历史，人类一直在不断寻求创新，利用越来越复杂的工具来提高效率和增强能力[1, 2]。这些工具不仅扩展了我们的智力，还扩展了我们的身体能力，对推动社会和文化进化至关重要[3]。从原始时代开始




图1 工具学习的开发轨迹图示。我们展示了具有发表年份和发表场所的论文统计数据，每个场所用不同的颜色唯一表示。对于每个时间段，我们选择了一系列具有代表性的里程碑研究，这些研究对该领域做出了重大贡献。（请注意，我们在图中使用第一作者的所属机构作为代表机构。）

从石器工具到先进机械，这一进步使我们的潜力超越了自然限制，使我们能够更复杂、更高效地管理任务[4]。

今天，我们正经历一场新的技术复兴，这得益于人工智能的突破，尤其是大型语言模型（LLMs）的发展。像ChatGPT这样的开创性模型已经展示了非凡的能力，在一系列自然语言处理（NLP）任务中取得了重大进展，包括摘要生成[6,7]、机器翻译[8,9]、问答[10,11]等。然而，尽管它们的能力令人赞叹，但大型语言模型往往在复杂的计算和提供准确、及时的信息方面存在困难，因为它们依赖于固定的和参数化的知识[12,13]。这种固有的限制经常导致响应看似合理，但实际上是事实不正确或过时的（通常称为幻觉）[14,15]，这会带来重大风险并误导用户。

随着大型语言模型能力的不断增强，预计它们将能够像人类一样熟练地使用工具来解决复杂问题[16]，这一概念被称为大型语言模型的工具学习。工具学习通过允许与外部工具进行动态交互，成为缓解大型语言模型这些限制的有希望的解决方案[17-20]。这种方法不仅增强了大型语言模型解决问题的能力，还扩大了它们的功能范围[21-23]。例如，大型语言模型可以使用计算器工具进行复杂的计算，通过天气API获取实时天气更新，并通过解释器执行编程代码[24,25]。这种集成显著提高了它们对用户查询的响应准确性，促进了更有效和可靠的交互。随着这一领域的不断发展，工具增强的大型语言模型有望在自然语言处理的未来中发挥关键作用[26,27]，提供更通用和适应性更强的解决方案[28,29]。

如图 1 所示，过去的一年见证了

随着大型语言模型（LLMs）的兴起，对工具学习的相关研究迅速增加。值得注意的是，在实际应用中，GPT-4[5]通过调用插件来解决其知识局限性并增强其能力，最终将插件返回的结果与其内部知识相结合，为用户生成更好的响应。在研究界，人们投入了大量精力探索如何评估大型语言模型的工具学习能力[30-32]以及如何增强这种能力以增强大型语言模型的能力[33-35]。鉴于对大型语言模型工具学习的日益关注和快速发展，系统地回顾最新的进展和挑战至关重要，以便让研究人员和工业开发者了解当前的进展并激发未来在该领域开展更多的工作。

在这项调查中，我们从两个主要维度对现有研究进行了系统探索：（1）为什么工具学习是有益的；（2）工具学习是如何实现的。具体来说，“为什么工具学习”维度既研究了工具集成的优势，也研究了工具学习范例的内在益处，而“如何工具学习”维度则详细描述了整个工具学习工作流程的四个阶段：任务规划、工具选择、工具调用和响应生成。这些维度对于理解大型语言模型中的工具学习至关重要。此外，我们对现有的基准和评估方法进行了系统总结，并根据它们在不同阶段的关注点对其进行分类。最后，我们讨论了当前的挑战并提出了未来的方向，为促进这一有前景且新兴的研究领域的开发提供了关键的见解。我们还维护了一个GitHub存储库，以持续跟踪这一新兴领域的相关论文和资源，网址为<https://github.com/quchangle1/LL>

M-Tool-Survey。

值得注意的是，虽然其他调查提供了对大型语言模型所使用的技术和方法的全面概述[36]，对规划[37]、推理[38,39]、代理[40-42]以及检索增强生成[43,44]的应用，它们经常提及工具或工具学习，但并未深入探讨这一方面。与它们相比，我们的调查对大型语言模型中的工具学习进行了集中和详细的分析，特别是阐明了工具学习对于大型语言模型至关重要的双重原因，以及如何系统地实现工具学习。通过这两个主要方面，我们对大型语言模型中的工具学习进行了最新的全面综述。同时，我们也承认早期观点论文（如Mialon等人（2023）[45]和Qin等人（2023）[16]）的基础性贡献，这些论文最初**强调**了工具为增强大型语言模型的能力所提供的有前景的机会。由于该领域迅速发展，出现了许多新的研究，我们的调查对这些最新发展提供了更广泛的介绍。此外，一项更新的调查[46]探讨了语言模型中采用的各种工具场景和方法，这为我们的全面综述提供了出色的补充。

本文剩余部分（如图2所示）的结构如下：我们首先介绍与工具学习相关的基本概念和术语（§2）。然后，我们从六个具体方面探讨工具学习对大型语言模型（LLM）的重要性（§3）。接着，我们系统地回顾了工具学习的最新进展，重点关注工具学习工作流程的四个不同阶段（§4）。最后，我们提供了工具学习的可用资源总结，包括基准和评估。




图 2 本文的整体结构。

方法 (§5)。接下来，我们讨论该领域当前的挑战，并概述未来研究的开放方向 (§6)。最后，我们通过总结关键发现来结束本次调查 (§7)。

2 背景

在本节中，我们对与工具学习相关的概念和术语进行了概述。

提供对该领域基本方面的更清晰的理解。

什么是工具？在增强型大型语言模型（LLM）的背景下，工具的定义非常广泛。米阿龙等人（2023）[45]将工具定义为“外部使用一个不连接或可操作的附加环境对象，以更有效地改变另一个对象的形式、位置或条件”。另一方面，王等人（2024）[46]将工具定义为“LM使用的工具是计算机程序的功能接口，运行在LM外部，LM生成函数调用和输入参数以使用工具”。同样，我们认为任何通过外部手段增强LLM的方法都符合工具的定义。值得注意的是，检索增强生成（RAG）是工具学习的特定实例，其中搜索引擎被用作LLM的工具。同时，“工具”的定义在不同论文中往往模糊不清且不一致。例如，一些研究明确地定义工具和API，认为工具是由多个API组成的聚合体[18, 33, 53]。相反，其他研究将每个API视为独立工具[19, 30, 122]。在本次调查中，遵循本文前面所确立的工具定义，我们将每个API视为一个单独的工具。

什么是工具学习？工具学习是指“旨在释放大型语言模型的能力，以有效地与各种工具交互，以完成复杂任务”的过程[18]。这种范例显著提高了大型语言模型解决复杂问题的能力。例如，当ChatGPT收到用户查询时，它会评估是否需要调用特定的工具。如果需要调用工具，ChatGPT会透明地概述使用该工具解决问题的过程，解释其响应背后的理由，

从而确保用户收到一个有充分依据的回答。此外，在初始解决方案失败的情况下，ChatGPT会重新评估其工具选择，并使用替代工具生成新的响应。

3 为何要学习工具？

在本节中，我们将从两个主要角度阐述工具学习对于大型语言模型（LLMs）的多方面重要性：工具整合带来的益处以及工具学习范例本身带来的益处。一方面，将工具整合到大型语言模型中增强了多个领域的能力，即知识获取、专业知识增强、自动化和效率以及交互增强。另一方面，采用工具学习范例增强了响应的稳健性和生成过程的透明度，从而提高了可解释性和用户信任度，并增强了系统的稳健性和适应性。后续的小节将详细阐述这六个方面，说明为什么工具学习对于大型语言模型至关重要。

3.1 知识获取

尽管大型语言模型（LLMs）在各个领域展示了其巨大的能力[161]，但它们的能力仍然受到预训练期间所学知识的限制[12]。这种嵌入的知识是有限的，并且缺乏获取最新信息的能力。此外，用户提供的提示可能会进一步影响大型语言模型的有效性，这些提示可能并不总是精心设计的。因此，大型语言模型容易生成看似表面合理但可能包含事实错误的内容，这被称为幻觉。一种有前景的方法是减轻

这些限制涉及增强大型语言模型（LLMs）访问外部工具的能力，这使得大型语言模型能够动态获取和整合外部知识。例如，搜索引擎工具的使用可以使大型语言模型访问当代信息[17, 28, 47-51]，而数据库工具的整合则允许大型语言模型访问结构化数据库以检索特定信息或执行复杂查询，从而扩展其知识库[52-57]。此外，与天气工具的连接允许实时更新天气状况、预报和历史数据[19,31,33]，与地图工具的交互使大型语言模型能够获取和提供地理数据，有助于导航和基于位置的查询[16]。通过这些增强，大型语言模型可以超越传统限制，提供更准确和上下文相关的输出。

3.2 专业能力提升

鉴于大型语言模型是在包含一般知识的数据集上进行训练的，它们的专业领域往往表现出不足。虽然大型语言模型在解决基本的数学问题方面表现出强大的问题解决能力，在加法、减法等运算方面表现出色，并在乘法任务中表现出一定的熟练程度，但当面对除法、指数、对数、三角函数和其他更复杂的复合函数时，其能力会显著下降[162, 163]。这种局限性也延伸到涉及代码生成[164,165]以及化学和物理问题[73, 74]等任务上，进一步凸显了它们在更专业领域的知识差距。因此，可以使用特定的工具来增强大型语言模型在特定领域的专业知识[60, 61, 76, 166]。例如，大型语言模型可以使用在线计算器或数学工具进行复杂的计算、求

解方程或分析统计数据[27,58-66]。此外，将外部编程资源（如Python编译器和解释器）集成到大型语言模型中，使得大型语言模型能够接收代码执行反馈，这对于优化代码以符合用户需求和优化代码生成至关重要[24, 25, 67-72]。此外，大型语言模型还可以利用化学[73-75]、生物学[76]、经济学[77-79]、医学[80,81]和推荐系统[35]等领域的工具来增强其特定领域的知识。这种方法不仅减少了大型语言模型中的专业知识差距，还通过提供特定领域的知识增强了其在专业应用中的实用性。

3.3 自动化与效率

大型语言模型本质上缺乏独立执行外部操作的能力，例如预订会议室或预订机票[46]。将大型语言模型与外部工具集成，可以通过简单地向工具界面填充必要参数来执行此类任务。例如，大型语言模型可以使用任务自动化工具来自动执行重复任务，如日程安排[17]、设置提醒[55]和过滤电子邮件[18]，从而增强其对用户辅助的实用性。此外，通过与项目管理和 workflow 工具进行交互，大型语言模型可以帮助用户管理任务、监控进展和优化工作流程[18]。此外，与在线购物助手集成不仅简化了购物过程[21]，还提高了处理效率和用户体验。此外，使用数据表处理工具使大型语言模型能够直接进行数据分析和可视化[16]，从而简化用户的数据操作过程。

3.4 交互增强

由于现实世界中用户查询的多样性和多面性，可能涵盖多种语言和模式，大型语言模型（LLMs）在持续理解不同类型输入方面经常面临挑战。这种可变性可能导致在辨别实际用户意图方面产生歧义[88]。专用工具的部署可以显著增强大型语言模型的感知能力。例如，大型语言模型可以利用多模态工具，如语音识别和图像分析，以更好地理解和响应更广泛的用户输入[29, 82-88]。此外，通过与机器翻译工具的交互，大型语言模型能够将它们不太熟练的语言转换为它们更有效地理解的语言[16,17]。此外，先进自然语言处理工具的整合可以增强大型语言模型的语言理解能力，从而优化对话管理和意图识别[18,89,90]。这些进步可能包括利用上下文理解模型来提升聊天机器人系统性能的平台。最终，改善感知输入和感官感知对于大型语言模型在处理复杂用户交互方面的能力提升至关重要。

3.5 增强的可解释性和用户信任

当前大型语言模型（LLMs）的一个主要问题是其不透明、“黑箱”的特性，这使得决策过程对用户不透明[167, 168]，从而严重缺乏可解释性。这种不透明性往往导致人们对大型语言模型提供的响应可靠性产生怀疑，并使确定其正确性变得困难[169]。此外，在高风险领域如航空、医疗保健和金融

中，可解释性尤为重要，因为准确性是必不可少的。因此，理解和解释大型语言模型对于阐明其行为至关重要[168]。一些研究通过使大型语言模型能够生成带有引用的文本来提高其准确性和可解释性[170,171]。相比之下，通过利用工具学习，大型语言模型可以展示其决策过程的每一步，从而使其操作更加透明[16]。即使在输出错误的情况下，这种透明度也能让用户迅速识别并理解错误的来源，从而促进对大型语言模型决策的理解和信任，从而增强有效的人机协作。

3.6 提高的稳健性和适应性

现有研究表明，大型语言模型对提示中的用户输入高度敏感[172-174]。对这些输入的微小修改就能引发响应中的重大变化，凸显出大型语言模型缺乏稳健性。在现实世界中，不同的用户有着不同的兴趣和提问方式，导致提示的多样性。将专门的工具集成作为一种减少对训练数据统计模式依赖的策略已被提出[16-18,54,89]。尽管用户的输入格式不同，但工具的输入和输出是相同的。这种增强提高了大型语言模型对输入扰动的抵抗力和对新环境的适应能力。因此，这种集成不仅能使模型在不确定性条件下稳定，还能降低与输入错误相关的风险。

4 工具学习如何？

在本节中，我们将首先介绍工具学习的总体范例，它包括四个不同的阶段和两种典型的范例。接下来




图 3 使用大型语言模型进行工具学习的总体工作流程。左侧部分展示了工具学习的四个阶段：任务规划、工具选择、工具调用和响应生成。右侧部分展示了两类工具学习的范例：一步任务解决的工具学习和迭代任务解决的工具学习。

在这个框架中，我们对工具学习工作流程中的每个阶段进行了详细回顾，并介绍了与每个阶段相关的最新进展。需要注意的是，许多工作涉及工具学习的多个阶段，但在此只讨论其核心阶段。对于每个阶段，我们还展示了利用GPT-4进行工具学习的实际、真实的例子，以解决特定问题，旨在帮助初学者更好地理解每个阶段的内容和实施方式。

4.1 工具学习的总体范例

在本节中，我们将介绍工具学习的整个过程，包括在利用工具增强的大型语言模型时所涉及到的四个阶段和两种范例。

工具学习的四个阶段。如图3左侧所示，工具学习的典型过程包括四个阶段：任务规划、工具选择、工具调用和响应生成，这在众多与工具相关的研究中都有采用[89, 93, 94]。这一过程概述了用户

与工具增强的大型语言模型（LLMs）的交互管道：对于用户的问题，初步阶段涉及大型语言模型分析用户请求以理解其意图，并将其分解为潜在的可解决子问题。随后，选择适当的工具来解决这些子问题。这种工具选择过程分为两种类型，基于是否使用检索器：基于检索器的工具选择和基于大型语言模型的工具选择。最近，人们越来越关注于最初使用检索器来过滤出最合适的k个工具[18, 34, 122]。这种必要性源于这样一个事实，即现实世界中的系统通常拥有大量的工具，由于长度和延迟的限制，将所有工具的描述作为大型语言模型的输入是不切实际的[124]。随后，将用户查询和所选工具提供给大型语言模型，使其能够选择最优工具并配置调用工具所需的必要参数。这要求大型语言模型对使用工具有敏锐的意识，并能够正确选择所需的工具。此外，对于大型语言模型来说，从用户查询中提取正确的工具参数是至关重要的，这个过程不仅要求参数内容的准确性，还要求符合特定的格式要求。在调用工具之后，大型语言模型会利用工具返回的结果为用户编写一个更优质的响应。

工具学习的两种范例。如图3右侧所示，使用工具学习的范例可以分为两种类型：一步任务解决的工具学习和迭代任务解决的工具学习。在Wang等人（2024）[40]的研究中，这些也被称为无反馈规划和有反馈规划，在Huang等人（2024）[37]的

研究中被称作分解优先和交错分解。在关于工具学习的早期研究中[17,69,89]，主要范例是一步任务解决的工具学习：在收到用户问题时，大型语言模型（LLMs）会分析用户请求以理解用户意图，并立即规划解决该问题所需的所有子任务。然后，大型语言模型会直接根据所选工具返回的结果生成响应，而不考虑过程中出现错误的可能性或根据工具反馈调整计划。后续研究引入了一种新的范例，称为迭代任务解决的工具学习[18,30,34,93]。这种方法不会预先制定完整的任务计划。相反，它允许与工具进行迭代交互，根据工具的反馈逐步调整子任务。这使得大型语言模型能够逐步解决问题，并根据工具返回的结果不断完善其计划，从而提高解决问题的能力。从单步方法到迭代方法的转变标志着工具学习领域的一项重大进步。

4.2 任务规划

一般来说，在现实世界的场景中，用户查询往往体现了复杂的意图。因此，首先进行任务规划以全面分析用户意图至关重要。这个阶段包括将用户问题分解为多个子问题，以满足指定的目标。此外，鉴于某些任务之间固有的依赖关系，规划者还负责勾勒出分解任务之间的依赖关系和执行顺序，从而促进子问题之间的相互连接。例如，以下是一个使用GPT-4进行任务规划的真实例子：

使用 GPT-4 进行任务规划的一个示例

指令提示：您当前处于任务规划阶段。您收到了一个需要多步操作和推理的用户查询。您需要将用户的查询分解为子问题，并且只需要输出这些子问题。确保通过最少数量的子问题全面覆盖原始问题。

用户问题：我想知道5盎司黄金加上100万股亚马逊股票的价值(以人民币计价)。

输出：1. 当前黄金每盎司的美元价格是多少？2. 亚马逊(AMZN)当前每股的股票价格是多少美元？3. 当前美元和人民币之间的汇率是多少？

使用迭代任务解决范例进行工具学习对于分阶段演示并不方便，因此本示例使用一步任务解决范例进行工具学习。从这个例子中，我们可以看到GPT-4将用户的问题分解为三个子问题。由于GPT-4的内部知识不包含最新的信息，有必要获取当前黄金和亚马逊(AMZN)股票的价格，以及美元和人民币的最新汇率。通过以这种方式分解查询，GPT-4可以逐步处理复杂的问题，展示其逻辑分析能力和处理多步任务的能力。接下来，我们将介绍两个类别的最新发展：无调优方法和基于调优的方法。

4.2.1 无需调优的方法

现有的研究[50,175,176]表明，大型语言模型(LLMs)的先天

能力能够通过诸如少样本甚至零样本提示等方法进行有效规划。例如，一些研究[177-180]利用提示将复杂任务分解为更简单的子任务，促进了结构化的行动计划。ART [50]构建了一个任务库，当遇到现实世界的任务时，它会从该库中检索示例作为少样本提示。RestGPT [93]引入了一种从粗到精的在线规划方法，这是一种迭代任务规划方法，使大型语言模型能够逐步改进任务分解的过程。HuggingGPT [89]利用了一个复杂的提示设计框架，该框架将基于规范的指令与基于演示的解析方法相结合。ToolChain* [95]通过将整个动作空间构建为一个决策树来采用一种规划机制，其中树中的每个节点代表一个潜在的API函数调用。TPTU [94]引入了一个专门为基于大型语言模型的人工智能代理设计的结构化框架，其中包含了两种不同类型的人工智能代理：一步代理和顺序代理。注意力桶[97]以独特的RoPE角度并行运行，形成相互补偿的独特波形，降低大型语言模型(LLM)遗漏关键信息的风险。ControlLLM [96]引入了一种称为思想图(ToG)的范例，利用深度优先搜索(DFS)在预先构建的工具图上识别解决方案。PLUTO[98]使用自回归规划方法通过生成假设、进行聚类分析和细化子查询来迭代地提高性能，直到满足初始查询。ATC[99]使大型语言模型能够通过使用工具链和黑箱探测方法独立学习和掌握新工具。工具规划器[181]根据具有相似功能的API函数将工具组织成工具包，使大型语言模型能够跨不同领域进行规划。

不同的工具包。SGC [100] 通过将图神经网络 (GNNs) 与大型语言模型 (LLMs) 相结合来增强任务规划, 使得在任务图中选择子任务更加高效和准确。Sum2Act [101] 通过在每一步总结进展并根据任务状态和错误调整动作来指导大型语言模型解决复杂任务。BTP [102] 在预算限制下为工具使用创建最优计划, 允许大型语言模型在解决用户查询的同时有效管理成本。DRAFT [103] 提出了一种新颖的框架, 旨在根据大型语言模型与外部工具之间的交互反馈动态调整和优化工具文档, 从而提高大型语言模型的理解和工具使用能力。

4.2.2 基于调优的方法

尽管大型语言模型在零样本或少样本设置下表现出色, 但与经过微调的模型相比, 其效果仍然较差[182]。Toolformer[17]采用API调用, 实际上有助于模型预测未来的标记, 以微调GPT-J, 从而增强大型语言模型有效利用工具的意识 and 能力。TaskMatrix.AI[104]利用人类反馈的强化学习 (RLHF) 来利用通过人类反馈获得的知识和见解, 从而增强基础模型。Toolink [105]通过将目标任务分解为解决问题的工具包, 然后使用模型通过链式解决 (CoS) 方法利用这些工具来回答查询进行创新。TPTU-v2[106]开发了一个大型语言模型微调器, 使用精心整理的数据集对基础大型语言模型进行微调, 以便微调后的大型语言模型能够更好地进行任务规划和API调用, 特别是针对特定领域的任务。 α -UMi[107]提出了一种新颖的两阶段训练范例, 其中首先对基础的大型语言模型进行广泛的微调, 然后复制它作为规划器, 以便在规划

任务上进行进一步的微调。COA [108] 训练大型语言模型 (LLMs) 首先用抽象占位符解码推理链, 然后调用域工具通过填充特定知识来具体化每个推理链。DEER [109] 通过自动生成具有多个决策分支的工具使用示例, 在各种场景中激发大型语言模型 (LLMs) 的决策意识, 并通过提出新颖的工具采样策略增强大型语言模型 (LLMs) 对未见过的工具的泛化能力。SOAY [111] 首先让大型语言模型 (LLMs) 根据复杂的用户输入生成可行的 API 调用计划, 即解决方案, 然后允许大型语言模型 (LLMs) 根据生成的解决方案生成可执行的 API 调用代码。TP-LLaMA [112] 引入了一种从思维树创建偏好数据的方法, 通过使用之前被忽略的失败探索, 为差分隐私优化 (DPO) 创建一个数据集来更新大型语言模型 (LLMs) 的策略。APIGen [113] 创建了一个用于生成多样化、高质量和可验证的函数调用数据集的自动化管道, 显著提高了使用此数据进行微调的模型的性能。

备注: 总之, 任务规划作为工具学习的初始阶段, 对于解决整个问题至关重要。尽管目前有许多方法可以提高大型语言模型的任务规划能力, 但在面对复杂问题时直接生成完美的规划仍然具有挑战性。此外, 工具学习是一个涉及大型语言模型与工具之间相互作用的过程。如何更好地利用工具的反馈来改进规划仍然是一个值得研究的问题。

4.3 工具选择

在任务规划阶段之后, 大型语言模型已经将用户的问题分解为多个子问题

问题。为了更好地回答这些子问题，需要选择适当的工具。工具选择过程包括通过检索器进行选择，或者直接让大型语言模型从提供的工具列表中进行选择。当工具数量过多时，通常会使用工具检索器来识别与子问题相关的排名前K的工具，并提供给大型语言模型，这一过程被称为基于检索器的工具选择。如果工具数量有限，或者在接收到工具检索阶段检索到的工具后，大型语言模型需要根据工具描述和子问题选择适当的工具，这一过程被称为基于大型语言模型的工具选择。例如，以下是一个使用GPT-4进行工具选择的例子：

指令提示：您当前处于工具选择阶段。您会收到可能用于解决子问题的候选工具。在候选工具中，选择一组有助于解决子问题的相关工具。

子问题 1：当前黄金每盎司的美元价格是多少？

候选工具：1. 金属价格费率 API:最新的 API 端点将返回每 60 秒更新的实时汇率数据。

2. Medium:获取来自 Medium 的官方新闻。

3.加密货币市场:近期发布的加密货币视频。

输出：1. 金属价格汇率 API:最新的 API 端点将返回每 60 秒更新的实时汇率数据。

子问题 2： ..

输出： ..

于获取黄金价格这一子问题，GPT-4能够正确选择必要的工具。具体来说，当面对多个候选工具时，GPT-4能够分析每个工具的特点，并选择最适合回答问题的那个。在这个例子中，GPT-4选择了金属价格率API，因为它提供实时更新的黄金价格信息。这展示了GPT-4在工具选择方面的准确性和有效性。接下来，我们将介绍两个类别中的最新发展：基于检索器的工具选择和基于大型语言模型的工具选择。

4.3.1 基于检索器的工具选择

现实世界的系统通常会整合各种各样的工具，由于篇幅限制和延迟限制，将所有工具的描述输入到大型语言模型中是不切实际的。因此，为了充分利用工具增强的大型语言模型的潜力，开发一个高效的工具检索系统至关重要。该系统旨在通过从庞大的工具集中为给定的查询高效地选择前K个最合适的工具，来弥合大型语言模型的广泛能力和输入大小的实际限制之间的差距。最先进的检索方法可以分为两类：基于术语的和基于语义的。

基于术语的方法。基于术语的方法（即稀疏检索）将文档和查询都表示为基于术语的高维稀疏向量，例如 TF-IDF [114] 和 BM25 [115] 所举例说明的。这些方法采用精确的术语匹配来实现查询和文档之间的有效对齐。例如，Gorilla [53] 采用 BM25 和 GPT-Index 来构建一个检索器以实现工具检索。

基于语义的方法。相反，基于语义的方法（即密集检索）利用神经网络

从这个例子中，我们可以看到，对

关系网络用于学习查询和工具描述之间的语义关系[116-120]，然后使用余弦相似度等方法计算语义相似度。最近，人们对更高效的工具检索器的开发和改进产生了浓厚的兴趣。一些研究[18, 34, 106]训练Sentence-Bert模型作为工具检索器，实现相关工具的高效检索。CRAFT[121]指导大型语言模型根据给定的查询生成虚构的工具描述，然后使用这个虚构的工具进行搜索。Anantha等人（2023）[122]基于任务分解的概念提出了ProTIP。Xu等人（2024a）[183]提出了一种利用大型语言模型的反馈逐步改进指令并使检索与工具使用对齐的方法来增强工具检索。COLT[124]提出了一种使用图神经网络的新型工具检索方法，指出传统工具检索方法中经常忽略的一个关键维度是确保检索到的工具的完整性。除了召回阶段，郑等人（2024）[123]还考虑了工具检索的重排序阶段。他们考虑了已见和未见工具之间的差异，以及工具库的分层结构。基于这些考虑，他们提出了一种自适应且分层感知的重排序方法，即ToolR-reank。同时，我们也可以直接使用现成的嵌入[184,185]来获取用户查询和工具描述表示。总之，构建一个高效的工具检索器至关重要。

备注：尽管传统的信息检索方法适用于工具检索场景，但它们仍然存在一些问题，例如只关注语义相似度而忽略了

工具的分层结构等。未来的工作应考虑工具检索场景中特有的需求和特点，以构建更有效的工具检索器。

4.3.2 基于 LLM 的工具选择

在工具库数量有限的情况下，或者在接收到从工具检索阶段获取的工具时，可以将这些工具的描述和参数列表与用户查询一起纳入输入上下文，提供给大型语言模型

（LLMs）。随后，大型语言模型根据用户查询从可用工具列表中选择合适的工具。鉴于查询的分辨率有时对调用工具的顺序敏感，因此需要串行调用工具，其中一个工具的输出可以作为另一个工具的输入参数。因此，这要求大型语言模型具备高度的推理能力。它必须根据当前可用的信息和需要获取的信息，熟练地选择正确的工具。现有的方法也可以分为无调优和基于调优的方法。

无调优方法。无调优方法利用大型语言模型（LLMs）的上下文学习能力，通过战略性的提示来实现[89,93]。例如，魏等人（2022）[91]引入了思维链（COT）的概念，有效地将“让我们一步一步思考”的指令融入到提示结构中。进一步推进这一讨论，姚等人（2022）[92]提出了ReACT框架，该框架将推理与行动结合起来，使大型语言模型不仅能够为行动提供理由，还能够根据环境反馈（例如工具的输出）来改进其推理过程。这一发展标志着向前迈进了一大步。

通过促进推理和行动之间的动态互动来增强大型语言模型的适应性和决策能力。基于这些见解,秦等人(2024) [18]提出了DFSDT方法,该方法通过引入深度优先搜索策略来解决误差传播问题,以提高决策的准确性。ChatCoT [125]将工具的使用融入多轮推理中,使大型语言模型能够无缝地将基于对话的推理与工具操作结合起来。ToolNet [126]将工具组织成一个有向图,使大型语言模型能够从一个初始工具节点开始,迭代地选择工具,直到任务完成。AnyTool [129]通过利用工具的分层结构设计了一个更高效的工具检索器。GeckOpt [130]通过添加意图驱动的门控来缩小工具选择范围。

基于调优的方法。基于调优的方法直接在工具学习数据集上对大型语言模型(LLMs)的参数进行微调,以掌握工具的使用。Tool-Bench [33]分析了开源大型语言模型在工具学习过程中面临的挑战,并指出微调,连同利用演示检索和系统提示,可以显著提高大型语言模型在工具学习中的效果。TRICE [128]提出了一个两阶段框架,最初采用行为克隆进行大型语言模型的指令调优,以模仿工具使用的行为,然后通过利用工具执行反馈通过 RLEF 进一步强化模型。ToolLLaMA [18]采用从 DFSDT 方法得出的指令解决方案对来微调 LLaMA 7B 模型。Confucius [34]承认工具复杂性的多样性,并提出了一种新颖的工具学习框架。ToolVerifier [127]引入了一种自验证方法,在工具选择期间通过自

问对比问题来区分密切的候选方案。

备注:通过比较上述方法,我们可以发现基于调优的方法通过修改模型参数来提高大型语言模型在工具选择方面的能力。这种方法可以整合关于工具的大量知识,但它只适用于开源的大型语言模型,并且会消耗大量的计算资源。相反,无调优的方法通过使用精确的提示策略或修改现有机制来增强大型语言模型在工具选择方面的能力,并且适用于所有大型语言模型。然而,由于设计提示的可能性是无限的,找到创建完美提示的理想方法仍然是一个重大挑战。

在实际应用中,可用工具的数量之多,加上诸如有限的上下文长度和高延迟等限制,使得同时向大型语言模型(LLM)呈现所有选项变得不切实际。为了应对这一挑战,通常首先采用传统的检索方法来过滤和缩小潜在工具的集合。这一初始步骤对于管理复杂性以及确保后续基于大型语言模型的选择既高效又有效至关重要。经过这一检索过程,大型语言模型随后可以优化选择,做出符合其推理和偏好的最终选择。这种两步走的方法突出了传统检索方法和基于大型语言模型的技术之间的互补作用,展示了它们在优化现实场景中的工具选择过程方面的集体重要性。

4.4 工具调用

在工具调用阶段,大型语言模型需要根据工具中概述的规范从用户查询中提取所需参数。

描述并从工具服务器请求数据。这一过程要求大型语言模型不仅要正确提取参数的内容和格式，还要严格遵守规定的输出格式，以防止生成多余的句子。例如，以下是一个使用 GPT-4 进行工具调用的

使用 GPT-4 进行工具调用的示例

指令提示：您当前处于工具调用阶段。您被提供了一些可能用于解决子问题的工具。您的目标是根据工具描述从子问题中提取调用该工具所需的参数。输出以下列格式呈现：
{参数名称: 参数, ..., 参数名称: 参数}

子问题 1: 当前黄金每盎司的美元价格是多少?

所选工具: 工具名称:{金属价格汇率 API}。工具描述:{最新的 API 端点将返回每 60 秒更新的实时汇率数据。} 所需参数:{ [名称:symbols, 类型:字符串,描述:输入以逗号分隔的货币代码或金属代码列表以限制输出代码,名称:base,类型:字符串,描述:输入您首选基础货币的三字母货币代码或金属代码。]}

输出: {符号: "XAU",基础货币:"USD"}

子问题 2: ..

输出: ..

从这个例子中，我们可以看到GPT-4能够根据提供的用户问题和所选工具的文档提取调用工具所需的参数。具体来说，GPT-4能够解析工具描述中的关键信息，

示例：准确识别需要提供的参数。接下来，我们将以与前两个阶段相同的方式介绍最新的发展，将其分为无调优方法和基于调优的方法。

4.4.1 无需调优的方法

无调优方法主要利用少样本方法为参数提取或基于规则的方法提供演示，从而增强大型语言模型识别参数的能力[93,96,126,186]。反向链[131]利用反向思维，首先为任务选择一个最终工具，然后让大型语言模型填充必要的参数；如果缺少任何参数，则根据描述选择额外的工具来完成它们并完成任务。EasyTool[132]通过提示ChatGPT重写工具描述，使其更简洁并直接将工具功能指南纳入描述中，增强大型语言模型对工具功能和参数要求的理解。Xu等人（2024b）[187]提出了一种将工具文档压缩为摘要序列的方法，同时保留关键信息，使大型语言模型能够高效使用工具，且性能损失最小。ConAgents[133]引入了一个多智能体协作框架，其中有一个专门的执行智能体负责参数提取和工具调用。

4.4.2 基于调优的方法

一些研究使用基于调优的方法来增强大型语言模型（LLMs）的工具调用能力[53,127,128]。例如，GPT4Tools [134]通过使用 LoRA 优化进行微调来增强开源的大型语言模型，从而整合工具使用能力。

技术，使用由 ChatGPT 生成的工具使用说明数据集。Toolkengpt [54] 使用称为“工具键”的特殊标记来无缝调用工具，在预测工具键时切换到特殊模式以生成所需的输入参数，并将输出集成回生成过程。Themis [135] 通过以自回归的方式集成工具使用和推理过程来增强阅读模型（RMs）的可解释性和评分可靠性，动态决定调用哪些工具、如何传递参数，并将结果有效地纳入推理过程。STE [136] 协调了生物系统中三个关键机制以成功使用工具：试错、想象和记忆，帮助大型语言模型（LLMs）准确使用其训练好的工具。

此外，鉴于在使用工具时经常出现调用错误，例如输入参数格式不正确、输入参数超出工具的可接受范围以及工具服务器错误，必须集成错误处理机制。这些机制旨在根据调用失败时返回的错误消息来优化操作。这使得系统更具弹性和适应性，即使在面临运营中断的情况下，也能确保工具学习的连续性和效率。

备注：总之，尽管基于调优的方法能够产生更好的结果，但它们严重依赖于训练集中出现的工具，对于数据集中未包含的新工具表现不佳。此外，它们还面临着灾难性遗忘和缺乏稳健泛化能力等挑战。相比之下，无调优方法具有显著的灵活性，并且不需要构建特定的数据集。因此，基于调优的方法和无调优的方法对于增强大型语言模型的工

具调用能力都至关重要。

4.5 响应生成

鉴于工具输出结果的多样性和复杂性，这些结果可以包括各种格式，如文本、数字、代码、视频和图像，直接向用户呈现这些结果往往是不切实际的。在收到工具的输出结果后，大型语言模型必须综合与用户查询相关的信息，并整合自身知识来构建全面的响应。例如，以下是一个使用GPT-4生成响应的示例：

使用 GPT-4 进行响应生成的示例

指令提示：您当前处于响应生成阶段。您收到了所选工具的输出结果，这些工具可能用于解决子任务。您的目标是基于工具的结果和您的内部知识生成对用户问题的响应。

用户问题：我想知道5盎司黄金加上100万股亚马逊股票的价值(以人民币计价)。

工具调用返回:AMZN 的股票价格为 130 美元,XAU USD 为 1919.7605807522993,美元与 YNC 之间的汇率为 7.24。

…人民币总价值:总价值=黄金人民币价值+股票人民币价值= 69、495.87 + 941、20万= 941,269、495.87 元。因此,5盎司黄金和100万股亚马逊股票的人民币总价值约为941 269 495.87……。

从这个例子中，我们可以看到GPT-4可以通过结合工具的结果和其内部知识来提供更好的响应。具体来说，GPT-4会使用工具提供的实时数据，例如

通过黄金和亚马逊股票的价格以及汇率，为用户的问题计算出最终答案。这展示了GPT-4整合多个信息源并进行复杂计算的能力。我们将这一阶段的最新进展分为两种类型：直接插入法和信息整合法。

4.5.1 直接插入法

早期工作中采用的方法包括将工具的输出直接插入到生成的响应中[17, 26, 46, 54]。例如，如果用户查询是“今天天气怎么样？”，大型语言模型生成的响应类似于“天气怎么样？”（如图3所示），随后会被工具返回的结果所取代（例如，从“天气怎么样？”到“阴雨”）。然而，由于工具的输出是不可预测的，这种方法可能会影响用户体验。

4.5.2 信息整合方法

大多数方法选择将工具的输出作为输入提供给大型语言模型（LLM），从而使得大型语言模型能够基于工具提供的信息生成更优质的回复[89,189,190]。然而，由于大型语言模型的上下文长度有限，一些工具的输出无法直接输入到大型语言模型中。因此，各种方法应运而生以解决这一问题。例如，RestGPT [93]使用预先创建的模式简化了冗长的结果，该模式是一种详细说明示例、格式和可能错误的文档。ToolLLaMA [18]采用截断方法，将输出裁剪以适应长度限制，这可能会丢失解决用户查询所需的信息。相反，ReCOMP [137]开发了一种压缩

器，将冗长的信息压缩成更简洁的格式，只保留最有用的信息。ConAgents [133]提出了一种无模式的方法，使得观察代理能够动态生成一个函数，以适应提取目标输出并遵循指令。并且一些研究表明，使用工具反馈来改进大型语言模型生成的响应，比调用工具后生成响应更有效[51,191,192]。

备注：总之，直接插入方法将工具输出直接嵌入到生成的响应中。这些方法简单明了，但仅适用于简单的工具输出。相反，信息整合方法允许大型语言模型处理工具结果以生成响应。这些方法更强大，可以提供更好的响应，增强用户体验。然而，未来的工作应该考虑如何解决与过长的工具输出和包括其他多种模态的问题。同时，一些研究强调，大型语言模型可以生成有偏见或有害的内容，并可能泄露敏感信息[193-195]。通过引入外部工具，无论是通过直接插入方法还是信息整合方法，生成的响应都会受到工具结果的影响，这有助于减轻大型语言模型本身产生的一些偏见和有害内容。尽管这些好处是显而易见的，但引入外部工具需要严格验证工具输出，以防止敌对攻击。没有足够的验证，攻击者可以操纵工具结果，导致大型语言模型生成有害或恶意的响应。未来的工作应集中于增强大型语言模型在工具输出中检测有害信息的能力，并开发有效的过滤机制以防止有害内容的生成。

表1 不同基准测试及其具体配置的详细列表。符号①、②、③和④分别代表工具学习任务规划、工具选择、工具调用和响应生成的四个阶段。

基准测试	专注	# 工具	# 实例	一般基准测试	工具来源	多工具?	可执行的?	时间
API 银行 [30]	①, ②, ③, ④	73	314	手动创建		✓	✓	2023-04
APIBench [53]	②, ③	1645	16, 450	公共模型		✗	✗	2023-05
工具台 1 [33]	②, ③	232	2746	公共应用程序编程接口		✗	✓	2023-05
工具: Alpaca [19]	②, ③, ④	426	3938	公共应用程序编程接口		✗	✗	2023-06
RestBench [93]	①, ②, ③	94	157	基于 RESTful 的 API		✓	✗	2023-06
工具台 2 [18]	①, ②, ③, ④	16, 464	126, 486	快速 API		✓	✓	2023-07
元工具 [31]	①, ②	199	21, 127	开放人工智能插件		✓	✗	2023-10
任务本[188]	①, ②, ③	103	28271	公共应用程序编程接口		✓	✓	2023-11
T 评估 [32]	①, ②, ③	15	533	手动创建		✓	✓	2023-12
工具眼[138]	①, ②, ③, ④	568	382	手动创建		✓	✓	2024-01
超级工具 [139]	①, ②, ③	2032	5824	手动创建		✓	✗	2024-01
API 混合油 [141]	②, ③	-	189,040	现有数据集		✓	✓	2024-02
印章工具 [140]	②, ③	4076	14,076	手动创建		✓	✗	2024-05
“捷径长椅 [142]”	②, ③	1,414	7627	公共应用程序编程接口		✓	✓	2024-07
《侠盗猎车手》 [143]	②, ③④	14	229	公共应用程序编程接口		✓	✓	2024-07
WTU 评估 [144]	①	4	916	BMTTools		✓	✓	2024-07
应用世界 [145]	①, ②, ③	457	750	快速API		✓	✓	2024-07
其他基准测试								
工具质量保证 [55]	质量保证	13	1530	手动创建		✗	✓	2023-06
工具模拟 [146]	安全	311	144	手动创建		✗	✓	2023-09
《工具对话》 [147]	对话	28	78	手动创建		✗	✓	2023-11
“ViIoT” [148]	视频通话	11	1841	公共模型		✗	✓	2023-12
RoTBench [149]	稳健性	568	105	工具眼		✓	✓	2024-01
MLLM 工具 [88]	多模态	932	11, 642	公共模型		✓	✓	2024-01
工具剑 [150]	安全	100	440	人工制作		✓	✓	2024-02
科学工具台[151]	科学推理	2446	856	手动创建		✓	✓	2024-02
InjecAgent [153]	安全	17	1054	公共应用程序编程接口		✗	✓	2024-02
稳定工具台 [152]	稳定	16, 464	126, 486	工具台 2		✓	✓	2024-03
M&M 巧克力豆[87]	多模态	33	4427	公共模型		✓	✓	2024-03
GeoLLM-QA [166]	遥感	117	1000	公共模型		✓	✓	2024-04
工具镜头 [124]	工具检索	464	18, 770	工具台 2		✓	✓	2024-05
SoAyBench [111]	学术探索	7	792	阿矿机		✓	✓	2024-05
工具沙盒 [155]	对话	34	1032	快速 API		✓	✓	2024-08
CToolEval [154]	中国人	398	6816	公共应用程序		✓	✓	2024-08

5 基准测试、工具包与评估

在本节中，我们系统地总结并分类了专门针对工具学习的各个阶段的基准、工

具包和评估方法。这为验证工具学习方法的有效性提供了结构化的评估协议和工具包的概述，旨在方便读者参与和实施工具学习。

5.1 基准测试

随着工具学习研究的推进，已经开发并提供了大量的基准。在我们的调查中，我们整理了一些流行的基准，如表¹所示。每个基准都评估了工具学习的不同方面，为各自领域做出了重要贡献。我们将这些基准分为两大类：通用基准和其他基准。

一般基准测试。鉴于当前对于大型语言模型（LLMs）有效利用工具的能力存在不确定性，已经建立了大量的基准测试来评估大型语言模型的工具学习能力。由于工具学习包含四个不同的阶段，现有的基准测试重点在于评估大型语言模型在不同阶段的能力。例如，MetaTool [31]和WTU-Eval [144]基准测试旨在评估大型语言模型是否能够认识到使用工具的必要性，并适当地选择最合适的工具来满足用户需求。这种评估特别关注任务规划和工具选择阶段。另一方面，APIBench [53]、ToolBench1 [33]、API-BLEND [141]和Seal-Tools [140]集中于评估大型语言模型准确选择正确工具并配置正确参数以调用工具的能力，分别对应于工具选择和工具调用阶段。此外，RestBench [93]、TaskBench [188]、T-Eval [32]和UltraTool [139]扩展了他们的关注点，包括任务规划、工具选择和工具调用，涵盖了四个阶段中的三个。后续研究如API-Bank [30]、ToolBench2 [18]，

而ToolEyes [138]对大型语言模型（LLMs）的工具使用能力进行了更全面的评估，涵盖了工具学习的所有四个阶段。值得注意的是，ToolBench2构建了现有的最大工具学习数据集，包含16464种工具和126486个实例。然而，这些基准中包含的工具往往存在质量问题，例如无法访问或无法使用。此外，这些基准中的查询通常由大型语言模型生成，可能无法准确反映用户的真正需求。相比之下，GTA [143]、ShortcutsBench [142]和App-World [145]通过收集现实世界的工具并生成由实际用户需求驱动查询，解决了这些局限性。

其他基准测试。除了一般基准测试外，还有专门为特定任务设计的基准测试。例如，ToolQA [55]专注于通过使用外部工具来增强大型语言模型（LLM）的回答问题能力，它开发了一个数据集，其中包含只有在这些外部工具的协助下大型语言模型才能回答的问题。ToolTalk [147]和ToolSandbox [155]专注于大型语言模型在轮对话中利用工具的能力。VioT [148]专注于大型语言模型使用VioT工具的能力。RoTBench [149]、ToolSword [150]和ToolEmu [146]是强调工具学习中的稳健性和安全性的基准测试。这些基准测试凸显了在工具学习应用中提高大型语言模型的稳健性和安全性的必要性。MLLM-Tool [88]和m&m's [87]将工具学习扩展到多模态领域，评估大型语言模型在多模态情境中的工具使用能力。同时，StableToolBench [152]主张为工具学习创建一个大规模且稳定的基准测试。SciToolBench [151]

¹Given the growing interest in tool learning, this survey may not encompass all benchmarks. We welcome suggestions to expand this list.

引入了一个名为工具增强科学推理的新任务，扩展了使用大型语言模型（LLMs）进行工具学习的边界。GeoLLM-QA[166]旨在捕捉复杂的遥感工作流程，其中大型语言模型处理复杂的数据结构、微妙的推理以及与动态用户界面的交互。此外，ToolLens[124]认识到现实世界中的用户查询往往简洁但具有模糊和复杂的意图，创建了一个专注于工具检索阶段的基准。在此基础上，SoayBench[111]专门关注学术信息搜索，提供了一个全面的基准数据集以及SOAYEval评估方法。最后，CToolEval[154]将工具学习的概念扩展到中国的社会应用中。CToolEval基准旨在评估大型语言模型在中国社会挑战的独特背景下的性能，强调大型语言模型在该领域的适用性和相关性。

5.2 工具包

最近，已经提出了几个用于实现工具学习的开源库和工具包。

LangChain 是一个由大型语言模型驱动的应用程序开发框架。它通过允许大型语言模型与 API、数据库和其他系统交互，实现复杂工作流程的创建。LangChain 非常适合构建智能助手和自动化系统。您可以通过以下链接访问它：github.com/langchain-ai/langchain。

Auto-GPT 是一个开源应用程序，旨在使大型语言模型能够以最少的人类输入自主执行复杂任务。它允许模型将目标分解为子任务并按顺序执行它们，包括访问互联网和与 API 交互。Auto-GPT 非常适合需要自主运行的项目，

如自动化内容创作和研究。可以通过以下链接访问它：github.com/Significant-Gravitas/Auto-GPT。

BabyAGI 是一个开源框架，用于创建自主的人工智能代理，以最小的监督来管理和执行任务。其模块化设计允许开发人员通过集成额外的工具或 API 来扩展功能，使其非常适合灵活和可扩展的自动化。您可以通过以下链接访问它：github.com/yoheinakajima/babyagi。

BMTools [16] 是一个开源库，旨在通过将大型语言模型（LLMs）与各种工具集成来增强它们，并提供了一个由社区驱动的平台来开发和分享这些工具。该库允许通过简单的 Python 函数轻松创建插件，并支持集成外部 ChatGPT 插件，使其成为扩展模型能力的有力资源。您可以通过以下链接访问它：github.com/openbmb/BMTools。

WebCPM [196] 是一个框架，旨在利用交互式网络搜索开发中文长文本问答应用程序。它允许大型语言模型模拟类似人类的网络浏览行为，从各种来源检索和综合信息。WebCPM 在创建复杂的工作流程方面表现出色，其中大型语言模型与搜索引擎交互，提取相关数据，并生成全面的答案。它可以通过以下链接访问：github.com/WebCPM/WebCPM。

5.3 评估

在本节中，我们将介绍与工具学习的四个阶段相对应的评估方法。

任务规划。任务规划能力

大型语言模型可以通过多种方式进行评估。首先，评估大型语言模型是否正确识别给定查询是否需要使用外部工具至关重要，测量工具使用意识准确性[31,139]。其次，应评估所提出的任务规划在解决查询方面的有效性，使用诸如ChatGPT提供的通过率[18]或人类评估[93]等指标。此外，可以通过将大型语言模型生成的计划与黄金解决方案进行比较，定量分析其精度，确保其一致性和准确性[18,32,93]。

工具选择。现有的工作从不同角度采用了几个指标来评估工具选择的有效性，包括召回率、NDCG 和 COMP。

Recall@K [156] 是通过计算所选的前 K 种工具中存在于真实工具集中的比例来衡量的：

$$\text{Recall@K} = \frac{1}{|Q|} \sum_{q=1}^{|Q|} \frac{|T_q^K \cap T_q^*|}{|T_q^*|},$$

其中，Q 是查询的集合， T_q^* 是针对查询 q 的相关工具集合， T_q^K 是模型为查询 q 选择的排名前 K 的工具。

NDCG@K [157] 度量标准不仅考虑了正工具的比例，还考虑了它们在列表中的位置：

$$\text{DCG}_q@K = \sum_{i=1}^K \frac{2^{g_i} - 1}{\log_2(i + 1)},$$

$$\text{NDCG@K} = \frac{1}{|Q|} \sum_{q=1}^{|Q|} \frac{\text{DCG}_q@K}{\text{IDCG}_q@K},$$

其中 g_i 是第 i 个所选工具的分级相关分数， $\text{IDCG}_q@K$ 表示在排名位置 k 的理想折扣累积增益。

COMP@K [124] 旨在

衡量所选的前 K 种工具相对于真实数据集是否构成一个完备集：

$$\text{COMP@K} = \frac{1}{|Q|} \sum_{q=1}^{|Q|} \mathbb{I}(\Phi_q \subseteq \Psi_q^K),$$

其中， Φ_q 表示查询 q 的真实工具集， Ψ_q^K 表示为查询 q 检索到的前 K 个工具， $\mathbb{I}(\cdot)$ 是一个指示函数，如果检索结果包含查询 q 的前 K 个结果中的所有真实工具，则返回 1，否则返回 0。

工具调用。在工具调用阶段，大型语言模型需要以指定格式生成工具调用请求。评估大型语言模型执行工具调用功能的有效性，可以通过评估大型语言模型输入的参数是否符合工具文档中的规定[32,138,139]。这种评估包括验证大型语言模型提供的参数是否与特定工具所需的参数一致，包括确认是否包含了所有必需的参数，以及输出参数是否符合所需的范围和格式。

响应生成。工具学习的最终目标是增强大型语言模型有效处理下游任务的能力。因此，工具利用的有效性通常基于解决这些下游任务的性能来评估[19, 138]。这就要求大型语言模型整合在整个过程中收集到的信息，为用户提供直接响应。最终响应的质量可以使用诸如 BLEU 分数[158]、ROUGE-L[159]、精确匹配[160]、F1[141]等指标进行评估。

6 挑战与未来方向

在本节中，我们指出了使用大型语言模型进行工具学习的当前挑战，并提出了一些有前景的未来研究方向。

6.1 工具学习中的高延迟

在推理过程中，大型语言模型经常面临高延迟和低吞吐量的挑战[197]，在整合工具学习时，这些挑战变得更加明显。例如，使用带有插件的ChatGPT进行简单查询可能需要5秒钟才能解决，与更快的搜索引擎相比，这会大大降低用户体验。探索减少延迟的方法至关重要，比如增强大型语言模型对工具利用的意识，使它们能够更好地评估何时真正需要使用工具。此外，保持工具的简单性和响应能力至关重要。应避免在单个工具上加载过多功能，以保持效率和有效性。

6.2 严格全面的评估

尽管当前的研究表明，使用大型语言模型进行工具学习取得了相当大的进展，这在各种应用中的实证研究中得到了体现，但在建立可靠的定量指标来评估和理解大型语言模型对工具的利用效果方面，仍然存在显著的差距。此外，虽然已经提出了许多策略来增强大型语言模型的工具学习能力，但这些方法缺乏全面的比较评估。例如，虽然人类评估能够准确反映人类偏好，但它与高昂的成本和重复性问题相关，缺

乏普遍适用性。虽然自动化评估方法ToolEval[18]提高了评估的效率和可重复性，但它不一定反映用户的真实偏好。需要建立一个严格和全面的评估框架，综合考虑效率、精度、成本和实用性。具体来说，该框架应为不同阶段的改进提供独立的评估和归因分析，明确它们对最终响应的具体贡献。这可能包括定义新的评估指标，并构建评估环境来模拟现实世界的复杂性。

6.3 全面且易用的工具

虽然现有的努力主要集中于利用工具来增强大型语言模型的能力，但这些工具的质量对工具学习的性能有着至关重要的影响[46]。当前大多数工具是从现有数据集或公共API中聚合而来的，这限制了它们的可访问性和全面性。此外，现有的数据集只包含有限的工具集，无法覆盖广泛的用户查询[90]。这些限制减少了工具学习的实用适用性和深度。此外，当前的工作从不同的来源获取工具，如公共API[19]、RESTful API[93]、Rapid API[18]、Hugging Face[53, 89, 188]或OpenAI插件列表[31]。这些工具来源的多样性导致描述格式的差异，阻碍了工具学习的统一框架的发展。迫切需要开发和编译一个更全面和易于访问的工具集。鉴于手动创建工具的巨大开销，一种可行的方法是利用大型语言模型进行大规模自动构建工具。

设定[198,199]。此外，工具集应该涵盖更广泛的领域，提供多样化的功能，以满足各个领域的具体需求。我们认为，一个全面且易于访问的工具集将极大地加速工具学习的进步。

6.4 安全且强大的工具学习

当前的研究主要强调大型语言模型在结构化环境中使用工具的能力，但忽略了与实际应用相关的噪声和新兴安全考虑因素的不可避免性。在将大型语言模型与工具学习应用于实际场景时，安全问题和噪声不可避免，需要采取深思熟虑的方法来抵御这些潜在的攻击。叶等人（2024）[149]引入了五个噪声级别（清洁、轻微、中等、严重和联合）来评估大型语言模型在工具学习中的稳健性。他们的研究表明，性能显著下降，揭示即使是最先进的模型 GPT-4，对干扰的抵抗能力也很差。此外，叶等人（2024）[150]设计了六个安全场景来评估大型语言模型在工具学习中的安全性，发现大型语言模型在安全意识方面存在显著缺陷，无法识别工具学习环境中的安全问题。随着工具学习系统在各个行业的广泛部署，对强大安全措施的需求显著增加。这需要深入研究和引入创新方法来增强这些系统的安全性和弹性。同时，由于预期到新的攻击手段，必须不断完善和更新安全策略，以适应快速发展的技术格局。

6.5 统一工具学习框架

如第4节所述，工具学习的整个过程可以分为四个不同的阶段。然而，现有的研究主要集中于解决特定问题的其中一个阶段，导致方法碎片化，缺乏标准化。这给实际场景的可扩展性和通用性带来了重大挑战。必须探索并开发一个全面的解决方案，将任务规划、工具选择、工具调用和响应生成纳入一个单一、统一的工具学习框架中。

6.6 工具学习的实际基准测试

尽管在工具学习领域已经开展了大量的工作，但现有基准测试中的大多数查询是由大型语言模型生成的，而不是源自真实世界的用户查询。这些合成的查询可能无法准确反映人类真正的兴趣以及用户进行搜索的方式。迄今为止，还没有发布包含用户与工具增强的大型语言模型之间真实交互的工具学习数据集。相信，发布这样一个数据集，并建立相应的基准测试，将极大地推动工具学习的发展。

6.7 多模态工具学习

虽然众多研究都专注于将大型语言模型（LLMs）与外部工具相连接以拓宽应用场景，但现有关于工具学习中大型语言模型的大部分工作都局限于基于文本的查询。这种局限性可能导致对用户真实意图的解读出现歧义。大型语言模型有望增强理解。

通过整合视觉和听觉信息来理解用户意图。多模态数据（如图像、音频、3D和视频）的使用日益增加，为进一步发展提供了重大机遇。这包括探索多模态大型语言模型在工具使用方面的能力，以及将多模态工具结合起来以生成更优质的响应。一些开创性的研究项目已经探索了这一领域。例如，Wang 等人（2024）[88]提出了MLLM-Tool，这是一个系统，它结合了开源的大型语言模型和多模态编码器，使学习到的大型语言模型能够感知多模态输入指令，并选择正确匹配的工具。尽管这些初步努力已经开展，但多模态输入下的工具学习的探索尚未得到广泛研究。全面了解多模态大型语言模型在工具使用方面的能力对于推动该领域的发展至关重要。

7 结论

在本文中，我们通过回顾150多篇论文，对使用大型语言模型进行工具学习进行了全面的综述。我们首先简要介绍了“工具”和“工具学习”的概念，为初学者提供了一个基础的概述和必要的背景知识。然后，我们阐明了工具集成和工具学习范例的好处，并详细讨论了六个具体方面，以强调工具学习对于大型语言模型的重要性。此外，为了更详细地介绍如何进行工具学习，我们将工具学习过程分为四个不同的阶段：任务规划、工具选择、工具调用和响应生成。每个阶段都进行了深入讨论，并结合了最新的研究进展，以提供对每个步骤的全

面理解。此外，我们还总结并分类了针对这些工具学习阶段的现有基准和评估方法，提供了一个结构化的评估协议概述。最后，我们强调了一些潜在的挑战，并指出了这一不断发展的领域未来的研究方向。我们希望这项调查能为热衷于利用大型语言模型在工具学习这一新兴领域进行探索的研究人员和开发者提供一个全面且极具价值的资源，从而为未来的研究努力铺平道路。

致谢 本研究得到中国国家重点研发计划（2023YFA1008704）、中国国家自然科学基金（编号：62377044）、北京市大数据管理与分析方法重点实验室、“双一流”重大创新与规划跨学科平台、中国人民大学世界一流大学（学科）建设资金以及 PCC@RUC 的资助。作者衷心感谢严开林在整个研究过程中给予的建设性反馈。

利益冲突 作者声明他们不存在利益冲突或财务冲突需要披露。

参考文献

1. Washburn S L. Tools and human evolution. *Scientific American*, 1960, 203(3): 62–75
2. Gibson K R, Gibson K R, Ingold T. Tools, language and cognition in human evolution. Cambridge University Press, 1993
3. Von Eckardt B. What is cognitive science? The MIT press, 1995
4. Shumaker R W, Walkup K R, Beck B B. Animal tool behavior: the use and manufacture of tools by animals. JHU Press, 2011
5. Achiam J, Adler S, Agarwal S, Ahmad L, Akkaya I, Aleman F L, Almeida D, Altenschmidt J, Altman S, Anadkat S, others. Gpt-4 technical report. arXiv preprint arXiv:2303.08774, 2023
6. El-Kassas W S, Salama C R, Rafea A A, Mohamed H K. Automatic text summarization: A comprehensive survey. *Expert systems with applications*, 2021, 165: 113679
7. Zhang T, Ladhak F, Durmus E, Liang P, McKeown K, Hashimoto T B. Benchmarking large language models for news summarization. *Transactions of the Association for Computational Linguistics*, 2024

8. Zhang B, Haddow B, Birch A. Prompting large language model for machine translation: A case study. In: International Conference on Machine Learning. 2023, 41092–41110
9. Feng Z, Zhang Y, Li H, Liu W, Lang J, Feng Y, Wu J, Liu Z. Improving llm-based machine translation with systematic self-correction. arXiv preprint arXiv:2402.16379, 2024
10. Yang Z, Qi P, Zhang S, Bengio Y, Cohen W W, Salakhutdinov R, Manning C D. Hotpotqa: A dataset for diverse, explainable multi-hop question answering. arXiv preprint arXiv:1809.09600, 2018
11. Kwiatkowski T, Palomaki J, Redfield O, Collins M, Parikh A, Alberti C, Epstein D, Polosukhin I, Devlin J, Lee K, others . Natural questions: a benchmark for question answering research. Transactions of the Association for Computational Linguistics, 2019, 7: 453–466
12. Mallen A, Asai A, Zhong V, Das R, Khashabi D, Hajishirzi H. When not to trust language models: Investigating effectiveness of parametric and non-parametric memories. arXiv preprint arXiv:2212.10511, 2022
13. Vu T, Iyyer M, Wang X, Constant N, Wei J, Wei J, Tar C, Sung Y H, Zhou D, Le Q, others . Freshllms: Refreshing large language models with search engine augmentation. arXiv preprint arXiv:2310.03214, 2023
14. Ji Z, Lee N, Frieske R, Yu T, Su D, Xu Y, Ishii E, Bang Y J, Madotto A, Fung P. Survey of hallucination in natural language generation. ACM Computing Surveys, 2023, 55(12): 1–38
15. Zhang Y, Li Y, Cui L, Cai D, Liu L, Fu T, Huang X, Zhao E, Zhang Y, Chen Y, others . Siren’s song in the ai ocean: a survey on hallucination in large language models. arXiv preprint arXiv:2309.01219, 2023
16. Qin Y, Hu S, Lin Y, Chen W, Ding N, Cui G, Zeng Z, Huang Y, Xiao C, Han C, others . Tool learning with foundation models. arXiv preprint arXiv:2304.08354, 2023
17. Schick T, Dwivedi-Yu J, Dessì R, Raileanu R, Lomeli M, Hambro E, Zettlemoyer L, Cancedda N, Scialom T. Toolformer: Language models can teach themselves to use tools. Advances in Neural Information Processing Systems, 2024, 36
18. Qin Y, Liang S, Ye Y, Zhu K, Yan L, Lu Y, Lin Y, Cong X, Tang X, Qian B, others . Toolllm: Facilitating large language models to master 16000+ real-world apis. In Proceedings of the 12th ICLR, 2024
19. Tang Q, Deng Z, Lin H, Han X, Liang Q, Sun L. Toolalpaca: Generalized tool learning for language models with 3000 simulated cases. arXiv preprint arXiv:2306.05301, 2023
20. Wang H, Qin Y, Lin Y, Pan J Z, Wong K F. Empowering large language models: Tool learning for real-world interaction. In: Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2024
21. Yao S, Chen H, Yang J, Narasimhan K. Webshop: Towards scalable real-world web interaction with grounded language agents. Advances in Neural Information Processing Systems, 2022, 35: 20744–20757
22. Lazaridou A, Gribovskaya E, Stokowiec W, Grigorev N. Internet-augmented language models through few-shot prompting for open-domain question answering. arXiv preprint arXiv:2203.05115, 2022
23. Lu Y, Yu H, Khashabi D. Gear: Augmenting language models with generalizable and efficient tool resolution. In Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics (EACL), 2023
24. Pan L, Wu X, Lu X, Luu A T, Wang W Y, Kan M Y, Nakov P. Fact-checking complex claims with program-guided reasoning. In: Rogers A, Boyd-Graber J, Okazaki N, eds, Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). July 2023, 6981–7004
25. Wang X, Wang Z, Liu J, Chen Y, Yuan L, Peng H, Ji H. Mint: Evaluating llms in multi-turn interaction with tools and language feedback. In Proceedings of 12th ICLR., 2024
26. Parisi A, Zhao Y, Fiedel N. Talm: Tool augmented language models. arXiv preprint arXiv:2205.12255, 2022
27. Karpas E, Abend O, Belinkov Y, Lenz B, Lieber O, Ratner N, Shoham Y, Bata H, Levine Y, Leyton-Brown K, others . Mrkl systems: A modular, neuro-symbolic architecture that combines large language models, external knowledge sources and discrete reasoning. arXiv preprint arXiv:2205.00445, 2022
28. Nakano R, Hilton J, Balaji S, Wu J, Ouyang L, Kim C, Hesse C, Jain S, Kosaraju V, Saunders W, others . Webgpt: Browser-assisted question-answering with human feedback. arXiv preprint arXiv:2112.09332, 2021
29. Surís D, Menon S, Vondrick C. Vipergpt: Visual inference via python execution for reasoning. In: Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023, 11888–11898
30. Li M, Zhao Y, Yu B, Song F, Li H, Yu H, Li Z, Huang F, Li Y. Api-bank: A comprehensive benchmark for tool-augmented llms. In: The 2023 Conference on Empirical Methods in Natural Language Processing. 2023

31. Huang Y, Shi J, Li Y, Fan C, Wu S, Zhang Q, Liu Y, Zhou P, Wan Y, Gong N Z, others . Metatool benchmark for large language models: Deciding whether to use tools and which to use. In Proceedings of 12th ICLR., 2024
32. Chen Z, Du W, Zhang W, Liu K, Liu J, Zheng M, Zhuo J, Zhang S, Lin D, Chen K, others . T-eval: Evaluating the tool utilization capability step by step. arXiv preprint arXiv:2312.14033, 2023
33. Xu Q, Hong F, Li B, Hu C, Chen Z, Zhang J. On the tool manipulation capability of open-source large language models. arXiv preprint arXiv:2305.16504, 2023
34. Gao S, Shi Z, Zhu M, Fang B, Xin X, Ren P, Chen Z, Ma J, Ren Z. Confucius: Iterative tool learning from introspection feedback by easy-to-difficult curriculum. In: In Proceedings of 38th Conference on Artificial Intelligence (AAAI). 2024
35. Zhao Y, Wu J, Wang X, Tang W, Wang D, De Rijke M. Let me do it for you: Towards llm empowered recommendation via tool learning. In: Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2024
36. Zhao W X, Zhou K, Li J, Tang T, Wang X, Hou Y, Min Y, Zhang B, Zhang J, Dong Z, others . A survey of large language models. arXiv preprint arXiv:2303.18223, 2023
37. Huang X, Liu W, Chen X, Wang X, Wang H, Lian D, Wang Y, Tang R, Chen E. Understanding the planning of llm agents: A survey. arXiv preprint arXiv:2402.02716, 2024
38. Qiao S, Ou Y, Zhang N, Chen X, Yao Y, Deng S, Tan C, Huang F, Chen H. Reasoning with language model prompting: A survey. arXiv preprint arXiv:2212.09597, 2022
39. Sun J, Zheng C, Xie E, Liu Z, Chu R, Qiu J, Xu J, Ding M, Li H, Geng M, others . A survey of reasoning with foundation models. arXiv preprint arXiv:2312.11562, 2023
40. Wang L, Ma C, Feng X, Zhang Z, Yang H, Zhang J, Chen Z, Tang J, Chen X, Lin Y, others . A survey on large language model based autonomous agents. Frontiers of Computer Science, 2024, 18(6): 1–26
41. Sumers T, Yao S, Narasimhan K, Griffiths T. Cognitive architectures for language agents. Transactions on Machine Learning Research, 2024
42. Xi Z, Chen W, Guo X, He W, Ding Y, Hong B, Zhang M, Wang J, Jin S, Zhou E, others . The rise and poten-tial of large language model based agents: A survey. arXiv preprint arXiv:2309.07864, 2023
43. Gao Y, Xiong Y, Gao X, Jia K, Pan J, Bi Y, Dai Y, Sun J, Wang H. Retrieval-augmented generation for large language models: A survey. arXiv preprint arXiv:2312.10997, 2023
44. Zhao P, Zhang H, Yu Q, Wang Z, Geng Y, Fu F, Yang L, Zhang W, Cui B. Retrieval-augmented generation for ai-generated content: A survey. arXiv preprint arXiv:2402.19473, 2024
45. Mialon G, Dess` R, Lomeli M, Nalmpantis C, Pasunuru R, Raileanu R, Rozi`ere B, Schick T, Dwivedi-Yu J, Celikyilmaz A, others . Augmented language models: a survey. arXiv preprint arXiv:2302.07842, 2023
46. Wang Z, Cheng Z, Zhu H, Fried D, Neubig G. What are tools anyway? a survey from the language model perspective, 2024
47. Komeili M, Shuster K, Weston J. Internet-augmented dialogue generation. In Proceedings of the 60st Annual Meeting of the Association for Computational Linguistics (ACL), 2022
48. Zhang K, Zhang H, Li G, Li J, Li Z, Jin Z. Toolcoder: Teach code generation models to use api search tools. arXiv preprint arXiv:2305.04032, 2023
49. Shi W, Min S, Yasunaga M, Seo M, James R, Lewis M, Zettlemoyer L, Yih W t. Replug: Retrieval-augmented black-box language models. arXiv preprint arXiv:2301.12652, 2023
50. Paranjape B, Lundberg S, Singh S, Hajishirzi H, Zettlemoyer L, Ribeiro M T. Art: Automatic multi-step rea-soning and tool-use for large language models. arXiv preprint arXiv:2303.09014, 2023
51. Gou Z, Shao Z, Gong Y, Shen Y, Yang Y, Duan N, Chen W. Critic: Large language models can self-correct with tool-interactive critiquing. In Proceedings of the 12th ICLR, 2024
52. Thoppilan R, De Freitas D, Hall J, Shazeer N, Kulshreshtha A, Cheng H T, Jin A, Bos T, Baker L, Du Y, others . Lamda: Language models for dialog applica-tions. arXiv preprint arXiv:2201.08239, 2022
53. Patil S G, Zhang T, Wang X, Gonzalez J E. Gorilla: Large language model connected with massive apis. arXiv preprint arXiv:2305.15334, 2023
54. Hao S, Liu T, Wang Z, Hu Z. Toolkengpt: Augmenting frozen language models with massive tools via tool em-beddings. Advances in neural information processing systems, 2024, 36
55. Zhuang Y, Yu Y, Wang K, Sun H, Zhang C. Toolqa: A dataset for llm question answering with external tools. Advances in Neural Information Processing Systems, 2024, 36
56. Zhang K, Chen H, Li L, Wang W. Syntax error-free and generalizable tool use for llms via finite-state decoding.

- Advances in Neural Information Processing Systems, 2024
57. Gu Y, Shu Y, Yu H, Liu X, Dong Y, Tang J, Srinivasa J, Latapie H, Su Y. Middleware for llms: Tools are instrumental for language agents in complex environments. arXiv preprint arXiv:2402.14672, 2024
 58. Cobbe K, Kosaraju V, Bavarian M, Chen M, Jun H, Kaiser L, Plappert M, Tworek J, Hilton J, Nakano R, others . Training verifiers to solve math word problems. arXiv preprint arXiv:2110.14168, 2021
 59. Shao Z, Huang F, Huang M. Chaining simultaneous thoughts for numerical reasoning. arXiv preprint arXiv:2211.16482, 2022
 60. Kadl^v c'  k M, Stef^v
anik M, Sotolar O, Martinek V. Calc-x and calcformers: Empowering arithmetical chain-of-thought through interaction with symbolic systems. In: The 2023 Conference on Empirical Methods in Natural Language Processing. 2023
 61. He-Yueya J, Poesia G, Wang R E, Goodman N D. Solving math word problems by combining language models with symbolic solvers. In Proceedings of the 2023 Annual Conference on Neural Information Processing Systems (NeurIPS), 2023
 62. Zhang B, Zhou K, Wei X, Zhao X, Sha J, Wang S, Wen J R. Evaluating and improving tool-augmented computation-intensive math reasoning. Advances in Neural Information Processing Systems, 2024, 36
 63. Gou Z, Shao Z, Gong Y, Yang Y, Huang M, Duan N, Chen W, others . Tora: A tool-integrated reasoning agent for mathematical problem solving. In Proceedings of the 12th ICLR, 2024
 64. Das D, Banerjee D, Aditya S, Kulkarni A. Mathsensei: A tool-augmented large language model for mathematical reasoning. arXiv preprint arXiv:2402.17231, 2024
 65. Veerendranath V, Shah V, Ghatge K. Calc-cmu at semeval-2024 task 7: Pre-calc –learning to use the calculator improves numeracy in language models. In Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT), 2024
 66. Bulusu A, Man B, Jagmohan A, Vempaty A, Mari-Wyka J, Akkil D. Mathviz-e: A case-study in domain-specialized tool-using agents. arXiv preprint arXiv:2407.17544, 2024
 67. Gao L, Madaan A, Zhou S, Alon U, Liu P, Yang Y, Callan J, Neubig G. Pal: Program-aided language models. In: International Conference on Machine Learning. 2023, 10764–10799
 68. Chen W, Ma X, Wang X, Cohen W W. Program of thoughts prompting: Disentangling computation from reasoning for numerical reasoning tasks. arXiv preprint arXiv:2211.12588, 2022
 69. Lu P, Peng B, Cheng H, Galley M, Chang K W, Wu Y N, Zhu S C, Gao J. Chameleon: Plug-and-play compositional reasoning with large language models. Advances in Neural Information Processing Systems, 2024, 36
 70. Wang X, Peng H, Jabbarvand R, Ji H. Leti: Learning to generate from textual interactions. arXiv preprint arXiv:2305.10314, 2023
 71. Wu J, Zhu R, Chen N, Sun Q, Li X, Gao M. Structure-aware fine-tuning for code pre-trained models. In Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING), 2024
 72. Zhang K, Li J, Li G, Shi X, Jin Z. Codeagent: Enhancing code generation with tool-integrated agent systems for real-world repo-level coding challenges. In Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (ACL), 2024
 73. Inaba T, Kiyomaru H, Cheng F, Kurohashi S. MultiTool-CoT: GPT-3 can use multiple external tools with chain of thought prompting. In: Rogers A, Boyd-Graber J, Okazaki N, eds, Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers). July 2023, 1522– 1532
 74. M. Bran A, Cox S, Schilter O, Baldassari C, White A D, Schwaller P. Augmenting large language models with chemistry tools. Nature Machine Intelligence, 2024
 75. Ramos M C, Collison C J, White A D. A review of large language models and autonomous agents in chemistry. arXiv preprint arXiv:2407.01603, 2024
 76. Jin Q, Yang Y, Chen Q, Lu Z. Genegpt: Augmenting large language models with domain tools for improved access to biomedical information. Bioinformatics, 2024, 40(2): btae075
 77. Theuma A, Shareghi E. Equipping language models with tool use capability for tabular data analysis in finance. In Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics (EACL), 2024
 78. Gao S, Wen Y, Zhu M, Wei J, Cheng Y, Zhang Q, Shang S. Simulating financial market via large language model based agents. arXiv preprint arXiv:2406.19966, 2024
 79. hang W, Zhao L, Xia H, Sun S, Sun J, Qin M, Li X, Zhao Y, Zhao Y, Cai X, others . A multimodal foundation agent for financial trading: Tool-augmented, diversified, and generalist. In: Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 2024

80. Jin Q, Wang Z, Yang Y, Zhu Q, Wright D, Huang T, Wilbur W J, He Z, Taylor A, Chen Q, others . Agentmd: Empowering language agents for risk prediction with large-scale clinical tool learning. arXiv preprint arXiv:2402.13225, 2024
81. Li B, Yan T, Pan Y, Xu Z, Luo J, Ji R, Liu S, Dong H, Lin Z, Wang Y. Mmedagent: Learning to use medical tools with multi-modal agent. arXiv preprint arXiv:2407.02483, 2024
82. Yang Z, Li L, Wang J, Lin K, Azarnasab E, Ahmed F, Liu Z, Liu C, Zeng M, Wang L. Mm-react: Prompting chatgpt for multimodal reasoning and action. arXiv preprint arXiv:2303.11381, 2023
83. Liu Z, He Y, Wang W, Wang W, Wang Y, Chen S, Zhang Q, Yang Y, Li Q, Yu J, others . Internchat: Solv-ing vision-centric tasks by interacting with chatbots beyond language. arXiv preprint arXiv: 2305.05662, 2023
84. Gao D, Ji L, Zhou L, Lin K Q, Chen J, Fan Z, Shou M Z. Assistgpt: A general multi-modal assistant that can plan, execute, inspect, and learn. arXiv preprint arXiv:2306.08640, 2023
85. Gao Z, Du Y, Zhang X, Ma X, Han W, Zhu S C, Li Q. Clova: A closed-loop visual assistant with tool usage and update. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2024
86. Zhao L, Yang Y, Zhang K, Shao W, Zhang Y, Qiao Y, Luo P, Ji R. Diffagent: Fast and accurate text-to-image api selection with large language model. In Proceed-ings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2024
87. Ma Z, Huang W, Zhang J, Gupta T, Krishna R. m&m's: A benchmark to evaluate tool-use for multi-step multi-modal tasks. arXiv preprint arXiv:2403.11085, 2024
88. Wang C, Luo W, Chen Q, Mai H, Guo J, Dong S, Li Z, Ma L, Gao S, others . Tool-lmm: A large multi-modal model for tool agent learning. arXiv preprint arXiv:2401.10727, 2024
89. Shen Y, Song K, Tan X, Li D, Lu W, Zhuang Y. Hugginggpt: Solving ai tasks with chatgpt and its friends in hugging face. *Advances in Neural Information Pro-cessing Systems*, 2024, 36
90. Lyu B, Cong X, Yu H, Yang P, Qin Y, Ye Y, Lu Y, Zhang Z, Yan Y, Lin Y, others . Gitagent: Facilitating autonomous agent with github by tool extension. arXiv preprint arXiv:2312.17294, 2023
91. Wei J, Wang X, Schuurmans D, Bosma M, Xia F, Chi E, Le Q V, Zhou D, others . Chain-of-thought prompting elicits reasoning in large language models. *Advances in neural information processing systems*, 2022, 35: 24824–24837
92. Yao S, Zhao J, Yu D, Du N, Shafran I, Narasimhan K, Cao Y. React: Synergizing reasoning and acting in language models. arXiv preprint arXiv:2210.03629, 2022
93. Song Y, Xiong W, Zhu D, Li C, Wang K, Tian Y, Li S. Restgpt: Connecting large language models with real-world applications via restful apis. arXiv preprint arXiv:2306.06624, 2023
94. Ruan J, Chen Y, Zhang B, Xu Z, Bao T, Du G, Shi S, Mao H, Zeng X, Zhao R. Tptu: Task planning and tool usage of large language model-based ai agents. arXiv preprint arXiv:2308.03427, 2023
95. Zhuang Y, Chen X, Yu T, Mitra S, Bursztyn V, Rossi R A, Sarkhel S, Zhang C. Toolchain*: Efficient action space navigation in large language models with a* search. In *Proceedings of the 12th ICLR*, 2024
96. Liu Z, Lai Z, Gao Z, Cui E, Li Z, Zhu X, Lu L, Chen Q, Qiao Y, Dai J, others . Controllm: Augment lan-guage models with tools by searching on graphs. arXiv preprint arXiv:2310.17796, 2023
97. Chen Y, Lv A, Lin T E, Chen C, Wu Y, Huang F, Li Y, Yan R. Fortify the shortest stave in attention: Enhanc-ing context awareness of large language models for effective tool use. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguis-tics (ACL)*, 2024
98. Huang T, Jung D, Chen M. Planning and editing what you retrieve for enhanced tool learning. In *Proceedings of the 2024 Conference of the North American Chap-ter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*, 2024
99. Shi Z, Gao S, Chen X, Feng Y, Yan L, Shi H, Yin D, Chen Z, Verberne S, Ren Z. Chain of tools: Large lan-guage model is an automatic multi-tool learner. arXiv preprint arXiv:2405.16533, 2024
100. Wu X, Shen Y, Shan C, Song K, Wang S, Zhang B, Feng J, Cheng H, Chen W, Xiong Y, others . Can graph learning improve task planning? arXiv preprint arXiv:2405.19119, 2024
101. Liu Y, Yuan Y, Wang C, Han J, Ma Y, Zhang L, Zheng N, Xu H. From summary to action: Enhancing large language models for complex tasks with open world apis. arXiv preprint arXiv:2402.18157, 2024
102. Zheng Y, Li P, Yan M, Zhang J, Huang F, Liu Y. Budget-constrained tool learning with planning. *Findings of the Association for Computational Linguistics: ACL 2024*, 2024
103. Qu C, Dai S, Wei X, Cai H, Wang S, Yin D, Xu J, Wen J R. From exploration to mastery: Enabling llms to master tools via self-driven interactions. arXiv preprint

arXiv:2410.08197, 2024

104. Liang Y, Wu C, Song T, Wu W, Xia Y, Liu Y, Ou Y, Lu S, Ji L, Mao S, others . Taskmatrix. ai: Completing tasks by connecting foundation models with millions of apis. *Advances in Neural Information Processing Systems*, 2024
105. Qian C, Xiong C, Liu Z, Liu Z. Toolink: Linking toolkit creation and using through chain-of-solving on open-source model. *arXiv preprint arXiv:2310.05155*, 2023
106. Kong Y, Ruan J, Chen Y, Zhang B, Bao T, Shi S, Du G, Hu X, Mao H, Li Z, Zeng X, Zhao R. Tptu-v2: Boost-ing task planning and tool usage of large language model-based agents in real-world systems, 2023
107. Shen W, Li C, Chen H, Yan M, Quan X, Chen H, Zhang J, Huang F. Small llms are weak tool learners: A multi-llm agent. *arXiv preprint arXiv:2401.07324*, 2024
108. Gao S, Dwivedi-Yu J, Yu P, Tan X E, Pasunuru R, Golovneva O, Sinha K, Celikyilmaz A, Bosselut A, Wang T. Efficient tool use with chain-of-abstraction reasoning. *arXiv preprint arXiv:2401.17464*, 2024
109. Gui A, Li J, Dai Y, Du N, Xiao H. Look before you leap: Towards decision-aware and generalizable tool-usage for large language models. *arXiv preprint arXiv:2402.16696*, 2024
110. Ge Y, Hua W, Mei K, Tan J, Xu S, Li Z, Zhang Y, others . Openagi: When llm meets domain experts. *Advances in Neural Information Processing Systems*, 2024, 36
111. Wang Y, Yu J, Yao Z, Zhang J, Xie Y, Tu S, Fu Y, Feng Y, Zhang J, Zhang J, others . A solution-based llm api-using methodology for academic information seeking. *arXiv preprint arXiv:2405.15165*, 2024
112. Chen S, Wang Y, Wu Y F, Chen Q G, Xu Z, Luo W, Zhang K, Zhang L. Advancing tool-augmented large language models: Integrating insights from errors in inference trees. *arXiv preprint arXiv:2406.07115*, 2024
113. Liu Z, Hoang T, Zhang J, Zhu M, Lan T, Kokane S, Tan J, Yao W, Liu Z, Feng Y, others . Apigen: Automated pipeline for generating verifiable and diverse function-calling datasets. *arXiv preprint arXiv:2406.18518*, 2024
114. Sparck Jones K. A statistical interpretation of term specificity and its application in retrieval. *Journal of documentation*, 1972, 28(1): 11–21
115. Robertson S, Zaragoza H, others . The probabilistic relevance framework: Bm25 and beyond. *Foundations and Trends® in Information Retrieval*, 2009, 3(4)
116. Reimers N, Gurevych I. Sentence-bert: Sentence embeddings using siamese bert-networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, 2019
117. Xiong L, Xiong C, Li Y, Tang K F, Liu J, Bennett P, Ahmed J, Overwijk A. Approximate nearest neighbor negative contrastive learning for dense text retrieval. In *Proceedings of 9th ICLR*, 2021
118. Hofstätter S, Lin S C, Yang J H, Lin J, Hanbury A. Efficiently teaching an effective dense retriever with balanced topic aware sampling. In: *Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval*. 2021, 113–122
119. Izacard G, Caron M, Hosseini L, Riedel S, Bojanowski P, Joulin A, Grave E. Unsupervised dense information retrieval with contrastive learning. *arXiv preprint arXiv:2112.09118*, 2021
120. Gao L, Callan J. Unsupervised corpus aware language model pre-training for dense passage retrieval. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2022
121. Yuan L, Chen Y, Wang X, Fung Y R, Peng H, Ji H. Craft: Customizing llms by creating and retrieving from specialized toolsets. In *Proceedings of 12th ICLR.*, 2024
122. Anantha R, Bandyopadhyay B, Kashi A, Mahinder S, Hill A W, Chappidi S. Protip: Progressive tool retrieval improves planning. *arXiv preprint arXiv:2312.10332*, 2023
123. Zheng Y, Li P, Liu W, Liu Y, Luan J, Wang B. Toolrerank: Adaptive and hierarchy-aware reranking for tool retrieval. In *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING)*, 2024
124. Qu C, Dai S, Wei X, Cai H, Wang S, Yin D, Xu J, Wen J R. Towards completeness-oriented tool retrieval for large language models. In: *Proceedings of the 33rd ACM International Conference on Information and Knowledge Management*. 2024, 1930–1940
125. Chen Z, Zhou K, Zhang B, Gong Z, Zhao X, Wen J R. Chatcot: Tool-augmented chain-of-thought reasoning on chat-based large language models. *Findings of the Association for Computational Linguistics: EMNLP 2023*, 2024
126. Liu X, Peng Z, Yi X, Xie X, Xiang L, Liu Y, Xu D. Tool-net: Connecting large language models with massive tools via tool graph. *arXiv preprint arXiv:2403.00839*, 2024
127. Mekala D, Weston J, Lanchantin J, Raileanu R, Lomeli M, Shang J, Dwivedi-Yu J. Toolverifier: Generalization to new tools via self-verification. *arXiv preprint arXiv:2402.14158*, 2024
128. Qiao S, Gui H, Chen H, Zhang N. Making language models better tool learners with execution feedback. In

- Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT), 2024
129. Du Y, Wei F, Zhang H. Anytool: Self-reflective, hierarchical agents for large-scale api calls. In Proceedings of ICML 2024, 2024
 130. Fore M, Singh S, Stamoulis D. Geckopt: Llm system efficiency via intent-based tool selection. arXiv preprint arXiv:2404.15804, 2024
 131. Zhang Y, Cai H, Chen Y, Sun R, Zheng J. Reverse chain: A generic-rule for llms to master multi-api planning. arXiv preprint arXiv:2310.04474, 2023
 132. Yuan S, Song K, Chen J, Tan X, Shen Y, Kan R, Li D, Yang D. Easytool: Enhancing llm-based agents with concise tool instruction. arXiv preprint arXiv:2401.06201, 2024
 133. Shi Z, Gao S, Chen X, Yan L, Shi H, Yin D, Chen Z, Ren P, Verberne S, Ren Z. Learning to use tools via cooperative and interactive agents. arXiv preprint arXiv:2403.03031, 2024
 134. Yang R, Song L, Li Y, Zhao S, Ge Y, Li X, Shan Y. Gpt4tools: Teaching large language model to use tools via self-instruction. Advances in Neural Information Processing Systems, 2024, 36
 135. Li L, Chai Y, Wang S, Sun Y, Tian H, Zhang N, Wu H. Tool-augmented reward modeling. arXiv preprint arXiv:2310.01045, 2023
 136. Wang B, Fang H, Eisner J, Van Durme B, Su Y. Llms in the imaginary: Tool learning through simulated trial and error. In Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL), 2024
 137. Xu F, Shi W, Choi E. Recomp: Improving retrieval-augmented llms with compression and selective augmentation. In Proceedings of 12th ICLR., 2024
 138. Ye J, Li G, Gao S, Huang C, Wu Y, Li S, Fan X, Dou S, Zhang Q, Gui T, others. Tooleyes: Fine-grained evaluation for tool learning capabilities of large lan-guage models in real-world scenarios. arXiv preprint arXiv:2401.00741, 2024
 139. Huang S, Zhong W, Lu J, Zhu Q, Gao J, Liu W, Hou Y, Zeng X, Wang Y, Shang L, others. Planning, creation, usage: Benchmarking llms for comprehensive tool utilization in real-world complex scenarios. arXiv preprint arXiv:2401.17167, 2024
 140. Wu M, Zhu T, Han H, Tan C, Zhang X, Chen W. Seal-tools: Self-instruct tool learning dataset for agent tuning and detailed benchmark. arXiv preprint arXiv:2405.08355, 2024
 141. Basu K, Abdelaziz I, Chaudhury S, Dan S, Crouse M, Munawar A, Kumaravel S, Muthusamy V, Kapanipathi P, Lastras L A. Api-blend: A comprehensive corpora for training and benchmarking api llms. arXiv preprint arXiv:2402.15491, 2024
 142. Shen H, Li Y, Meng D, Cai D, Qi S, Zhang L, Xu M, Ma Y. Shortcutsbench: A large-scale real-world benchmark for api-based agents. arXiv preprint arXiv:2407.00132, 2024
 143. Wang J, Ma Z, Li Y, Zhang S, Chen C, Chen K, Le X. Gta: A benchmark for general tool agents. arXiv preprint arXiv:2407.08713, 2024
 144. Ning K, Su Y, Lv X, Zhang Y, Liu J, Liu K, Xu J. Wtu-eval: A whether-or-not tool usage evaluation benchmark for large language models. arXiv preprint arXiv:2407.12823, 2024
 145. Trivedi H, Khot T, Hartmann M, Manku R, Dong V, Li E, Gupta S, Sabharwal A, Balasubramanian N. Appworld: A controllable world of apps and people for benchmarking interactive coding agents. arXiv preprint arXiv:2407.18901, 2024
 146. Ruan Y, Dong H, Wang A, Pitis S, Zhou Y, Ba J, Dubois Y, Maddison C J, Hashimoto T. Identifying the risks of lm agents with an lm-emulated sandbox. arXiv preprint arXiv:2309.15817, 2023
 147. Farn N, Shin R. Tooltalk: Evaluating tool-usage in a conversational setting. arXiv preprint arXiv:2311.10775, 2023
 148. Zhong Y, Qi M, Wang R, Qiu Y, Zhang Y, Ma H. Viotgpt: Learning to schedule vision tools towards intelligent video internet of things. arXiv preprint arXiv:2312.00401, 2023
 149. Ye J, Wu Y, Gao S, Li S, Li G, Fan X, Zhang Q, Gui T, Huang X. Rotbench: A multi-level benchmark for evaluating the robustness of large language models in tool learning. arXiv preprint arXiv:2401.08326, 2024
 150. Ye J, Li S, Li G, Huang C, Gao S, Wu Y, Zhang Q, Gui T, Huang X. Toolsword: Unveiling safety issues of large language models in tool learning across three stages. arXiv preprint arXiv:2402.10753, 2024
 151. Ma Y, Gou Z, Hao J, Xu R, Wang S, Pan L, Yang Y, Cao Y, Sun A. Sciagent: Tool-augmented lan-guage models for scientific reasoning. arXiv preprint arXiv:2402.11451, 2024
 152. Guo Z, Cheng S, Wang H, Liang S, Qin Y, Li P, Liu Z, Sun M, Liu Y. Stabletoolbench: Towards stable large-scale benchmarking on tool learning of large language models. arXiv preprint arXiv:2403.07714, 2024
 153. Zhan Q, Liang Z, Ying Z, Kang D. Injecagent: Benchmarking indirect prompt injections in tool-integrated large language model agents. arXiv preprint arXiv:2403.02691, 2024

154. Guo Z, Huang Y, Xiong D. Ctooleval: A chinese benchmark for llm-powered agent evaluation in real-world api interactions. Findings of the Association for Computational Linguistics: ACL 2024, 2024
155. Lu J, Holleis T, Zhang Y, Aumayer B, Nan F, Bai F, Ma S, Ma S, Li M, Yin G, others . Toolsandbox: A stateful, conversational, interactive evaluation benchmark for llm tool use capabilities. arXiv preprint arXiv:2408.04682, 2024
156. Zhu M. Recall, precision and average precision. Department of Statistics and Actuarial Science, University of Waterloo, Waterloo, 2004, 2(30): 6
157. Järvelin K, Kekäläinen J. Cumulated gain-based evaluation of ir techniques. ACM Transactions on Information Systems (TOIS), 2002, 20(4): 422–446
158. Papineni K, Roukos S, Ward T, Zhu W J. Bleu: a method for automatic evaluation of machine translation. In: Isabelle P, Charniak E, Lin D, eds, Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics. July 2002, 311–318
159. Lin C Y. Rouge: A package for automatic evaluation of summaries. In: Text summarization branches out. 2004, 74–81
160. Blackwell M, Iacus S, King G, Porro G. cem: Coarsened exact matching in stata. The Stata Journal, 2009, 9(4): 524–546
161. Ouyang L, Wu J, Jiang X, Almeida D, Wainwright C, Mishkin P, Zhang C, Agarwal S, Slama K, Ray A, others . Training language models to follow instructions with human feedback. Advances in neural information processing systems, 2022, 35: 27730–27744
162. Dao X Q, Le N B. Investigating the effectiveness of chatgpt in mathematical reasoning and problem solving: Evidence from the vietnamese national high school graduation examination. arXiv preprint arXiv:2306.06331, 2023
163. Wei T, Luan J, Liu W, Dong S, Wang B. Cmath: can your language model pass chinese elementary school math test? arXiv preprint arXiv:2306.16636, 2023
164. Chen M, Tworek J, Jun H, Yuan Q, Pinto H P d O, Kaplan J, Edwards H, Burda Y, Joseph N, Brockman G, others . Evaluating large language models trained on code. arXiv preprint arXiv:2107.03374, 2021
165. Austin J, Odena A, Nye M, Bosma M, Michalewski H, Dohan D, Jiang E, Cai C, Terry M, Le Q, others . Program synthesis with large language models. arXiv preprint arXiv:2108.07732, 2021
166. Singh S, Fore M, Stamoulis D. Evaluating tool-augmented agents in remote sensing platforms. arXiv preprint arXiv:2405.00709, 2024
167. Linardatos P, Papastefanopoulos V, Kotsiantis S. Explainable ai: A review of machine learning interpretability methods. Entropy, 2020, 23(1): 18
168. Zhao H, Chen H, Yang F, Liu N, Deng H, Cai H, Wang S, Yin D, Du M. Explainability for large language models: A survey. ACM Transactions on Intelligent Systems and Technology, 2024, 15(2): 1–38
169. Weidinger L, Mellor J, Rauh M, Griffin C, Uesato J, Huang P S, Cheng M, Glaese M, Balle B, Kasirzadeh A, others . Ethical and social risks of harm from language models. arXiv preprint arXiv:2112.04359, 2021
170. Gao T, Yen H, Yu J, Chen D. Enabling large language models to generate text with citations. In: Bouamor H, Pino J, Bali K, eds, Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. December 2023, 6465–6488
171. Sun H, Cai H, Wang B, Hou Y, Wei X, Wang S, Zhang Y, Yin D. Towards verifiable text generation with evolving memory and self-reflection. arXiv preprint arXiv:2312.09075, 2023
172. Wallace E, Feng S, Kandpal N, Gardner M, Singh S. Universal adversarial triggers for attacking and analyzing NLP. In: Inui K, Jiang J, Ng V, Wan X, eds, Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). November 2019, 2153–2162
173. Jin D, Jin Z, Zhou J T, Szolovits P. Is bert really robust? a strong baseline for natural language attack on text classification and entailment. In: Proceedings of the AAAI conference on artificial intelligence. 2020
174. Wu F, Zhang N, Jha S, McDaniel P, Xiao C. A new era in llm security: Exploring security concerns in real-world llm-based systems. arXiv preprint arXiv:2402.18649, 2024
175. Zhang J. Graph-toolformer: To empower llms with graph reasoning ability via prompt augmented by chatgpt. arXiv preprint arXiv:2304.11116, 2023
176. Li C, Yang R, Li T, Bafarassat M, Sharifi K, Bergemann D, Yang Z. Stride: A tool-assisted llm agent framework for strategic and interactive decision-making. arXiv preprint arXiv:2405.16376, 2024
177. Huang W, Abbeel P, Pathak D, Mordatch I. Language models as zero-shot planners: Extracting actionable knowledge for embodied agents. In: International Conference on Machine Learning. 2022, 9118–9147
178. Chern I, Chern S, Chen S, Yuan W, Feng K, Zhou C, He J, Neubig G, Liu P, others . Factool: Factual-ity detection in generative ai—a tool augmented framework for multi-task and multi-domain scenarios. arXiv preprint arXiv:2307.13528, 2023
179. Xu S, Pang L, Shen H, Cheng X, Chua T s. Search-in-

- the-chain: Towards the accurate, credible and traceable content generation for complex knowledge-intensive tasks. In: Proceedings of the ACM Web Conference 2024. 2024
180. Kim G, Baldi P, McAleer S. Language models can solve computer tasks. *Advances in Neural Information Processing Systems*, 2024, 36
 181. Liu Y, Peng X, Zhang Y, Cao J, Zhang X, Cheng S, Wang X, Yin J, Du T. Tool-planner: Dynamic solution tree planning for large language model with tool clustering. *arXiv preprint arXiv:2406.03807*, 2024
 182. Erbacher P, Falissar L, Guigue V, Soulier L. Navigating uncertainty: Optimizing api dependency for hallucination reduction in closed-book question answering. *arXiv preprint arXiv:2401.01780*, 2024
 183. Xu Q, Li Y, Xia H, Li W. Enhancing tool retrieval with iterative feedback from large language models. *arXiv preprint arXiv:2406.17465*, 2024
 184. Xiao S, Liu Z, Zhang P, Muennighoff N. C-pack: Pack-aged resources to advance general chinese embedding, 2023
 185. Team G, Anil R, Borgeaud S, Alayrac J B, Yu J, Soricut R, Schalkwyk J, Dai A M, Hauth A, others . Gemini: A family of highly capable multimodal models, 2024
 186. Hsieh C Y, Chen S A, Li C L, Fujii Y, Ratner A, Lee C Y, Krishna R, Pfister T. Tool documentation enables zero-shot tool-usage with large language models. *arXiv preprint arXiv:2308.00675*, 2023
 187. Xu Y, Feng Y, Mu H, Hou Y, Li Y, Wang X, Zhong W, Li Z, Tu D, Zhu Q, others . Concise and precise context compression for tool-using language models. *Findings of the Association for Computational Linguistics: ACL 2024*, 2024
 188. Shen Y, Song K, Tan X, Zhang W, Ren K, Yuan S, Lu W, Li D, Zhuang Y. Taskbench: Benchmarking large language models for task automation. *arXiv preprint arXiv:2311.18760*, 2023
 189. Wang H, Wang H, Wang L, Hu M, Wang R, Xue B, Lu H, Mi F, Wong K F. Tpe: Towards better compositional reasoning over conceptual tools with multi-persona collaboration. *arXiv preprint arXiv:2309.16090*, 2023
 190. Qian C, Han C, Fung Y, Qin Y, Liu Z, Ji H. Creator: Tool creation for disentangling abstract and concrete reasoning of large language models. In: *Findings of the Association for Computational Linguistics: EMNLP 2023*. 2023, 6922–6939
 191. Jacovi A, Caciularu A, Herzig J, Aharoni R, Bohnet B, Geva M. A comprehensive evaluation of tool-assisted generation strategies. *Findings of the Association for Computational Linguistics: EMNLP 2023*, 2023
 192. Nathani D, Wang D, Pan L, Wang W Y. Maf: Multi-aspect feedback for improving reasoning in large language models. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, 2023
 193. Yao Y, Duan J, Xu K, Cai Y, Sun Z, Zhang Y. A survey on large language model (llm) security and privacy: The good, the bad, and the ugly. *High-Confidence Computing*, 2024, 100211
 194. Cui T, Wang Y, Fu C, Xiao Y, Li S, Deng X, Liu Y, Zhang Q, Qiu Z, Li P, others . Risk taxonomy, mitigation, and assessment benchmarks of large language model systems. *arXiv preprint arXiv:2401.05778*, 2024
 195. Das B C, Amini M H, Wu Y. Security and privacy challenges of large language models: A survey. *arXiv preprint arXiv:2402.00888*, 2024
 196. Qin Y, Cai Z, Jin D, Yan L, Liang S, Zhu K, Lin Y, Han X, Ding N, Wang H, Xie R, Qi F, Liu Z, Sun M, Zhou J. Webcpm: Interactive web search for chinese long-form question answering. In: *Proceedings of ACL 2023*. 2023
 197. Miao X, Oliaro G, Zhang Z, Cheng X, Jin H, Chen T, Jia Z. Towards efficient generative large language model serving: A survey from algorithms to systems. *arXiv preprint arXiv:2312.15234*, 2023
 198. Cai T, Wang X, Ma T, Chen X, Zhou D. Large language models as tool makers. In *Proceedings of the 12th ICLR.*, 2024
 199. Wang Z, Fried D, Neubig G. Trove: Inducing verifiable and efficient toolboxes for solving programmatic tasks. In *Proceedings of ICML 2024*, 2024



常乐渠目前在中国人民大学高瓴人工智能学院的攻读博士学位。他目前的研究兴趣主要包括利用大型语言模型进行工具学习和信息检索。



孙浩岱是中国人民大学高瓴人工智能学院的博士研究生。他目前的研究兴趣在于推荐系统和信息检索。他在诸如 KDD、SIGIR、ICDE、CIKM 和 RecSys 等顶级会议上发表了多篇论文。



魏晓驰于 2018 年在北京理工大学获得博士学位，师从黄和岩教授。他曾访问新加坡国立大学。



戴伟银于 2013 年在利哈伊大学获得博士学位。他是百度公司的工程高级总监。他负责管理搜索科学团队。

2015 年至 2016 年，在蔡大生教授的指导下。他是百度公司的一名高级研发工程师。他的研究兴趣包括问答、多媒体信息检索和推荐系统。他曾在多个会议中担任程序委员会成员，例如美国人工智能协会 (AAAI)、国际人工智能联合会 (IJCAI)、美国计算机协会 (ACL) 和自然语言处理会议 (EMNLP)。



蔡恒毅于 2021 年在中国科学院计算技术研究所获得博士学位（优秀毕业生）。他于 2021 年夏天加入了京东的博士管理培训生计划。此前，他是百度的一名研究实习生。

2020 年搜索科学团队，在大卫·尹博士的指导下。他的研究兴趣包括对话系统、问答和信息检索。他曾担任或正在担任包括 ACL、EMNLP、KDD、NeurIPS 和 SIGIR 等顶级会议的 PC 成员。



王帅强分别于 2004 年和 2009 年在山东大学获得计算机科学的学士和博士学位。他目前是一名首席算法

曾在百度公司担任工程师。此前，他是京东公司的研究科学家。在此之前，他曾是英国曼彻斯特大学和芬兰于韦斯亚斯卡大学的一名助理教授。近年来，他担任了国际人工智能联合会议 (IJCAI) 的高级程序委员会成员，以及世界万维网会议 (WWW)、信息检索学会 (SIGIR) 和数据挖掘会议 (WSDM) 的程序委员会成员。他广泛地对包括信息检索、推荐系统和数据挖掘在内的多个研究领域感兴趣。

百度。此前，他在 2016 年至 2019 年期间担任京东的高级总监，负责管理推荐工程团队。在京东之前，他是雅虎实验室的高级研究经理，领导相关性科学团队，并负责雅虎搜索的核心搜索相关性。他的研究兴趣包括数据挖掘、应用机器学习、信息检索和推荐系统。他在顶级会议和期刊上发表了 100 多篇研究论文，并荣获了 2016 年 WSDM 最佳论文奖、2016 年 KDD 最佳论文奖、2018 年 WSDM 最佳学生论文奖。

徐军是中国人民大学高瓴人工智能学院的教授。他的研究兴趣集中在排序和语义方面。



网络搜索中的匹配。他曾担任或正在担任信息检索学会 (SIGIR)、万维网会议 (WWW) 和美国人工智能协会 (AAAI) 的特别项目主席，《信息科学与技术杂志》(JASIST) 的编委会成员，以及美国计算机协会 (ACM)《信息与通信技术学报》(TOIS) 的副主编。他获得了信息检索学会 (SIGIR) 的“时间考验奖荣誉提名” (2019 年)、美国信息科学学会 (AIRS) 的“最佳论文奖” (2010 年) 以及美国计算机协会 (CIKM) 的“最佳论文亚军奖” (2017 年)。



文继荣是中国人民大学 (RUC) 的教授。他还是中国人民大学信息学院的院长以及高瓴人工智能学院的执行院长。

他的主要研究兴趣包括信息检索、数据挖掘和机器学习。他曾是微软亚洲研究院 (MSRA) 网络搜索与挖掘小组的高级研究员和小组经理。